Метрики качества сети состояний с цензурой

конспект к `survpm.metrics`

23 октября 2026

1 Постановка

Модель. Сеть состояний с одним токеном. Из состояния s выход $s \to d$ выбирается с вероятностью p_{sd} ($\sum_d p_{sd} = 1$), время перехода $T_{sd} \sim f_{sd}(t;\theta_{sd})$, $S_{sd}(t) = P(T_{sd} > t)$. Наблюдения — интервалы ожидания в состоянии: завершённый (s, d, t) и цензурированный (s, c), у которого известно только, что ожидание длилось не меньше c, а выход неизвестен.

Правдоподобие с цензурой.

$$\log L = \sum_{(s,d,t)} \log\bigl(p_{sd}\, f_{sd}(t)\bigr) + \sum_{(s,c)} \log \sum_d p_{sd}\, S_{sd}(c).$$

Модель `censor_aware` максимизирует $\log L$; модель `naive` — только первую сумму. Семейство f_{sd} выбирается по $\mathrm{AIC} = 2k - 2\log L$ на завершённых интервалах обучения.

Протокол. 5-fold кросс-валидация по целым трассам, фолды равны по доле цензурированных трасс (`crossval.cross_validate`). Обе модели оцениваются на 4/5 трасс, метрики считаются на оставшейся 1/5. Итог — среднее и стандартное отклонение по фолдам, а также попарная разница $\Delta = \text{censor_aware} - \text{naive}$ внутри фолда (`paired_differences`).

Варианты А и Б.

- **А** — только полные тестовые трассы (дошли до терминала).
- **Б** — все тестовые трассы; цензурированная трасса считается *префиксом*. Как именно это учитывается, сказано у каждой метрики.

2 Уровень 1: process mining (`metrics.process`)

Сравниваются две сети Петри: сеть состояний модели (без места `CENS`) и сеть Inductive Miner, обе построены по обучающим трассам. Метрики — PM4Py.

Fitness по token replay. Для журнала суммируются по трассам пропущенные m, потреблённые c, оставшиеся r и произведённые p фишки:

$$\mathrm{fitness}_{\mathrm{tok}} = \tfrac{1}{2}\Bigl(1 - \tfrac{m}{c}\Bigr) + \tfrac{1}{2}\Bigl(1 - \tfrac{r}{p}\Bigr).$$

В варианте Б цензурированная трасса проигрывается с пустой финальной маркировкой, поэтому её оставшиеся фишки не штрафуются (r берётся только по полным трассам).

Fitness по alignments (только A). Для трассы σ находится оптимальное выравнивание γ_σ со стоимостью $\delta(\gamma_\sigma)$ (ход только в журнале или только в модели стоит 1):

$$\text{fitness}_{\text{align}} = 1 - \frac{\sum_\sigma \delta(\gamma_\sigma)}{\sum_\sigma \big(|\sigma| + \min_{\tau \in M} |\tau|\big)}.$$

Precision (ETC). Для каждого префикса h журнала сравниваются разрешённые моделью переходы $\text{en}(h)$ и реально встреченные в журнале продолжения; лишние разрешённые переходы — «escaping», $\text{esc}(h)$:

$$\text{precision} = 1 - \frac{\sum_h w_h \, |\text{esc}(h)|}{\sum_h w_h \, |\text{en}(h)|},$$

w_h — число трасс с префиксом h. Метрика построена на префиксах, поэтому в варианте Б цензурированные трассы входят как есть. Есть версии по token replay и по alignments (только A).

Generalization. Если переход t сработал n_t раз при проигрывании журнала,

$$\text{generalization} = 1 - \frac{1}{|T|} \sum_{t \in T} \frac{1}{\sqrt{n_t}}.$$

Simplicity (по степени дуг). При средней степени узла $\bar{k}$ сети

$$\text{simplicity} = \frac{1}{1 + \max(0,\ \bar{k} - 2)}.$$

Сеть состояний строится из всех переходов обучения, поэтому на обучении её fitness равен 1; меньше единицы он бывает только из-за переходов, которых в обучении не было.

3 Уровень 2: вероятности путей (`metrics.stochastic`)

Модель переводится в стохастический детерминированный автомат (SDFA, `to_sdfa`): состояние — место сети, метка перехода — состояние назначения, вероятность — p_{sd}. В варианте Б в каждом состоянии добавляется остановка с наблюдаемой вероятностью цензуры $q_s = N_{s,\text{cens}}/N_{s,\text{visits}}$, остальные вероятности умножаются на $1 - q_s$. $P_M(\sigma)$ — вероятность трассы в автомате, $P_L(\sigma)$ — её доля в тестовом журнале. Вероятности округляются до 10^{-3}: Ebi считает точно, в рациональных числах, и при длинных знаменателях падает с «cannot compute ER».

Entropic relevance (Ebi, бит на трассу, меньше — лучше). Пусть ρ — доля тестовых трасс с $P_M(\sigma) > 0$, Λ — алфавит. Тогда

$$\text{ER} = H_0(\rho) + \sum_\sigma P_L(\sigma) \begin{cases} -\log_2 P_M(\sigma), & P_M(\sigma) > 0, \\ (|\sigma| + 1)\log_2(|\Lambda| + 1), & P_M(\sigma) = 0, \end{cases}$$

где $H_0(\rho) = -\rho \log_2 \rho - (1 - \rho)\log_2(1 - \rho)$ — цена кодирования того, какие трассы модель допускает.

uEMSC (unit Earth Movers' Stochastic Conformance, Ebi, больше — лучше):

$$\text{uEMSC} = 1 - \sum_\sigma \max\big(P_L(\sigma) - P_M(\sigma),\ 0\big).$$

EMD языков (меньше — лучше). Язык модели оценивается по 5000 симулированным трассам ($\hat{P}_M$). Расстояние между трассами — нормированный Левенштейн:

$$d(\sigma, \sigma') = \frac{\mathrm{Lev}(\sigma, \sigma')}{\max(|\sigma|, |\sigma'|)},$$

$$\mathrm{EMD} = \min_{\pi \in \Pi(P_L, \hat{P}_M)} \sum_{\sigma, \sigma'} \pi(\sigma, \sigma')\, d(\sigma, \sigma'),$$

Π — совместные распределения с заданными маргиналами. Транспортная задача решается пакетом POT (`ot.emd2`); матрица только «варианты журнала × варианты модели».

4 Уровень 3: время (`metrics.temporal`)

Для сравнения журналов модель симулируется столько раз, сколько тестовых трасс, с теми же моментами входа. В варианте Б симулированная трасса обрывается в момент цензуры парной тестовой трассы, в А — не обрывается.

Temporal profile (PM4Py). Для каждой пары активностей (a, b), где b идёт после a в одной трассе, по эталонному журналу оцениваются среднее μ_{ab} и стандартное отклонение s_{ab} времени между ними. Трасса отклоняется, если хоть для одной пары $|t_b - t_a - \mu_{ab}| > \zeta\, s_{ab}$ (по умолчанию $\zeta = 6$). Метрика `temporal_deviation_share` — доля тестовых трасс с отклонениями. Эталон — симуляция модели; строка `train_log` — базовая линия с профилем по обучающему журналу.

Расстояния журналов (log-distance-measures; тест L против симуляции S):

- `cfld` — control-flow log distance: трассы L и S попарно сопоставляются (задача о назначениях) по нормированному расстоянию Дамерау–Левенштейна, берётся среднее расстояние в оптимальном сопоставлении;
- `ngram_3` — гистограммы 3-грамм активностей h_L, h_S: $\sum_g |h_L(g) - h_S(g)| \,/\, \sum_g \big(h_L(g) + h_S(g)\big)$;
- `cycle_time_emd` — одномерный EMD (Вассерштейн-1) между распределениями длительностей трасс, бины по 1 часу, в часах;
- `absolute_event_emd` — то же для абсолютных моментов событий, в часах.

KS по рёбрам. Для ребра $e = s \to d$ с n_e завершёнными тестовыми интервалами

$$D_e = \sup_t \big|\hat{F}_e(t) - F_e(t; \hat{\theta}_e)\big|, \qquad \text{edge_ks} = \frac{\sum_e n_e D_e}{\sum_e n_e}.$$

Цензурированные интервалы не входят: их выход неизвестен.

Время до терминала. Модель симулируется без цензуры (5000 трасс), T_j — время от старта до терминала, $S_M(t) = \frac{1}{N} \sum_j \mathbf{1}\{T_j > t\}$. По тестовым трассам с длительностью t_i и признаком исхода δ_i строится оценка Каплана–Майера

$$\hat{S}_{KM}(t) = \prod_{t_{(k)} \le t} \Big(1 - \frac{d_k}{n_k}\Big),$$

d_k — число исходов в момент $t_{(k)}$, n_k — число трасс под наблюдением. Эти метрики сами учитывают цензуру, поэтому записываются в строку Б.

- $\text{km_sup} = \max_{t \in [0, t_{\max}]} |S_M(t) - \hat{S}_{KM}(t)|$;

- km_l1_days $= \int_0^{t_{\max}} |S_M(t) - \hat{S}_{KM}(t)|\, dt$ (в днях);
- log-rank (lifelines): тест равенства функций выживания тестовой выборки (с цензурой) и симуляции; `logrank_statistic` — статистика χ^2_1, `logrank_p` — p-value. На больших выборках отвергает гипотезу даже при малом расхождении, поэтому главное — `km_sup` и `km_l1_days`;
- integrated Brier score (scikit-survival) с весами IPCW, $\hat{G}$ — оценка Каплана–Майера для цензуры по обучающим трассам:

$$\mathrm{BS}(t) = \frac{1}{n} \sum_i \Big[\frac{S_M(t)^2\, \mathbf{1}\{t_i \le t,\ \delta_i = 1\}}{\hat{G}(t_i)} + \frac{(1 - S_M(t))^2\, \mathbf{1}\{t_i > t\}}{\hat{G}(t)} \Big],$$

$$\mathrm{IBS} = \frac{1}{t_b - t_a} \int_{t_a}^{t_b} \mathrm{BS}(t)\, dt.$$

  Сетка — 15 квантилей времён исхода от 10% до 80%; тестовые трассы длиннее максимальной обучающей исключаются (иначе $\hat{G}$ не определена).

5 Уровень 4: обобщение (`CensoredStateNet.nll`)

Отрицательное правдоподобие с цензурой (формула из раздела 1) на тестовых интервалах:

$$\mathrm{nll_per_interval} = -\frac{\log L_{\text{test}}}{N_{\text{int}}}, \qquad \mathrm{nll_per_trace} = -\frac{\log L_{\text{test}}}{N_{\text{traces}}}.$$

Одна формула для обеих моделей, меньше — лучше. Тестовые трассы с переходом или состоянием, которых не было в обучении, из $\log L$ исключаются без сглаживания; их доля — отдельная метрика `unseen_share`.

6 Сводка

Метрика	Лучше	Варианты
fitness, precision (token)	больше	А, Б
fitness, precision (alignments)	больше	А
generalization, simplicity	больше	А, Б
entropic relevance	меньше	А, Б
uEMSC	больше	А, Б
EMD языков	меньше	А, Б
temporal_deviation_share	меньше	А, Б
cfld, ngram_3	меньше	А, Б
cycle_time_emd, absolute_event_emd	меньше	А, Б
edge_ks	меньше	А, Б (одинаковы)
km_sup, km_l1_days, ibs	меньше	Б
logrank_p	больше	Б
nll_per_interval, nll_per_trace	меньше	—
unseen_share	справочно	—