Функции выживания со сдвигом на время перехода

расчёт свёрткой на сетке в `survpm`

26 октября 2026

1 Что есть сейчас

Модель. Сеть состояний с одним токеном. Из состояния s выход $s \to d$ выбирается с вероятностью p_{sd}, затем токен ждёт в s время $\Delta t \sim f_{sd}$ (CDF G_{sd}, $S_{sd} = 1 - G_{sd}$), отсчитанное от момента прихода в s. Параметры p_{sd} и f_{sd} оцениваются совместной MLE с цензурой (`estimate_network`).

Время процесса. Нас интересует T — время от входа в начальное состояние (Registration) до конечного (Discharge), и $S(t) = P(T > t)$. Это сумма Δt по случайному пути, поэтому каждое следующее ожидание начинается со сдвигом на момент прихода в своё состояние.

Как считается сейчас. `CensoredStateNet.survival()` делает это Монте-Карло: `simulate()` прогоняет $n = 10\,000$ трасс, на каждом шаге выбирает выход по p_{sd} и прибавляет Δt, случайно сгенерированное из f_{sd}. Затем

$$\hat{S}(t) = 1 - \frac{\#\{i :\ T_i \le t\}}{n},$$

где $T_i = \infty$, если трасса до Discharge не дошла. Кривая ступенчатая, шумит (максимальное отклонение от эталона около 0.013, табл. 1) и зависит от `seed`. Кривые «из промежуточного состояния» и прогноз для незавершённого случая не считаются.

2 Что предлагается

2.1 Уравнение со сдвигом

Для каждого состояния s введём

$$F_s(t) = P\big(\text{пришедший в } s \text{ в момент 0 токен дойдёт до Discharge к } t\big), \quad S_s = 1 - F_s.$$

Если первый переход из s произошёл в момент u в состояние d, то на оставшийся путь осталось $t - u$. Усредняя по выбору выхода и по u:

$$F_s(t) = \sum_d p_{sd} \int_0^t f_{sd}(u)\, F_d(t-u)\, du, \qquad F_{\text{Discharge}} \equiv 1, \qquad F_s \equiv 0 \text{ для тупиков.} \tag{1}$$

Функция следующего состояния F_d берётся со сдвигом на u — момент прихода в d. Это уравнение марковского восстановления для полумарковского процесса; порядок «сначала выбор, потом время» тот же, что в правдоподобии, по которому оценена модель. Искомая кривая $S(t) = 1 - F_{\text{Registration}}(t)$, а остальные F_s получаются попутно.

Пример. Для цепочки $A \to B \to D$: $F_B = G_{BD}$ и $F_A(t) = \int_0^t f_{AB}(u)\, G_{BD}(t-u)\, du$, то есть обычная свёртка двух времён. В сети с ветвлениями и циклами явной формулы нет, поэтому (1) решается на сетке.

2.2 Расчёт на сетке

Возьмём шаг h и округлим время каждого перехода до ближайшего узла jh. Масса узла

$$g_{sd}[0] = G_{sd}(h/2), \qquad g_{sd}[j] = G_{sd}\big((j+\tfrac{1}{2})h\big) - G_{sd}\big((j-\tfrac{1}{2})h\big),\ j \geq 1.$$

Интеграл в (1) превращается в сумму

$$F_s[k] = \sum_d p_{sd}\, g_{sd}[0]\, F_d[k] \ + \ \underbrace{\sum_d p_{sd} \sum_{j=1}^{k} g_{sd}[j]\, F_d[k-j]}_{b_s[k]}.$$

Второе слагаемое $b_s[k]$ зависит только от уже посчитанных $F[0..k-1]$. Первое описывает переходы короче полушага (в Sepsis их много: часть переходов длится минуты); они связывают состояния в один момент, поэтому для всех нетерминальных состояний сразу решается система

$$(I - P_0)\, F[k] = b[k] + P_0^{\to \mathrm{Discharge}}, \qquad (P_0)_{sd} = p_{sd}\, g_{sd}[0].$$

Матрица $I - P_0$ одна для всех k и обращается один раз. Так счёт идёт вперёд по $k = 0, 1, 2, \ldots$, и циклы (возвраты в состояние) ему не мешают.

Полшага. После округления событие «время $\leq kh$» соответствует истинному «времени $\leq (k+\frac{1}{2})h$», поэтому $F[k]$ относится к моменту $(k+\frac{1}{2})h$. С этим сдвигом ошибка убывает как $O(h^2)$: на цепочке $\mathrm{Exp}(1) \to \mathrm{Exp}(1)$ она $1.2 \cdot 10^{-3}$ при $h = 0.1$ и $1.2 \cdot 10^{-5}$ при $h = 0.01$ (без сдвига было бы $1.9 \cdot 10^{-2}$ и $1.8 \cdot 10^{-3}$).

Цена. $O(E\,K^2)$ операций, E — число рёбер, $K = \lceil \text{горизонт}/h \rceil$. Масса за горизонтом просто не учитывается, поэтому горизонт должен покрывать интересующие t.

2.3 Прогноз для идущего случая

Пусть токен уже a дней находится в s. Тогда выходы, которые «должны были» сработать раньше, становятся менее вероятны, а ожидание — условным:

$$p_{sd}(a) = \frac{p_{sd}\, S_{sd}(a)}{\sum_{d'} p_{sd'}\, S_{sd'}(a)}, \qquad f_{sd}(u \mid a) = \frac{f_{sd}(a+u)}{S_{sd}(a)},$$

$$F(t \mid s, a) = \sum_d p_{sd}(a) \int_0^t f_{sd}(u \mid a)\, F_d(t-u)\, du.$$

Здесь t отсчитывается от текущего момента, а F_d берутся из уже посчитанной сетки, так что нужна лишь одна свёртка на каждый выход. Если с начала процесса прошло τ, то в абсолютном времени $S(t \mid \tau) = S(t - \tau \mid s, a)$. Для экспонент $F(t \mid s, a) = F_s(t)$ (отсутствие памяти), это проверяется в тестах.

2.4 Роль цензуры

Цензура входит только в оценку p_{sd} и f_{sd}. Кривые (1) описывают процесс без потери наблюдения, как и симуляция с `censoring=False`. С данными их сравнивают через Каплана–Майера (метрики `km_sup`, `ibs` в `survpm.metrics`).

3 Реализация

Новый модуль `survpm/curves.py` (ядро, только numpy/scipy) и методы модели:

`model.survival(t, method='grid', step=None)`	$S(t)$ свёрткой; по умолчанию $h = \max t/2000$
`model.state_curves(horizon, step=None)`	таблица $S_s(t)$ для всех состояний
`model.residual_survival(s, a, t)`	$S(t \mid s, a)$ для идущего случая
`curves.completion_cdf(edges, terminal, horizon, step)`	матрица $F_s[k]$

По умолчанию `survival()` по-прежнему симулирует (`method='sim'`), поэтому ноутбуки и метрики дают те же числа. Генерация трасс и оценка не менялись.

4 Проверка

Эталон — симуляция на 200 000 трасс; её собственный шум по супремуму порядка 0.002–0.003, поэтому меньшие расхождения уже не различимы.

Таблица 1: $\sup_t |S(t) - S_{\text{эталон}}(t)|$ и время счёта

	симуляция, $n = 10^4$		сетка	
сеть	отклонение	сек	отклонение	сек
A–D, истинная ($h = 0.05$)	0.011	1.35	0.0009	0.06
A–D, оценённая ($h = 0.05$)	0.014	1.05	0.0014	0.05
Sepsis, 12 рёбер ($h = 0.5$)	0.013	2.43	0.012	0.005
Sepsis ($h = 0.1$)			0.0038	0.03
Sepsis ($h = 0.02$)			0.0016	0.35

На Sepsis грубый шаг $h = 0.5$ дня даёт заметную ошибку: многие переходы короче шага. Шаг порядка 0.02–0.1 дня (полчаса–2 часа) даёт точность выше симуляции и считается быстрее неё. Прогноз остатка (состояние B сети A–D, $a = 0, 2, 8$ дней) совпадает с Монте-Карло на 40 000 трасс с отклонением ≤ 0.005 (рис. 3).

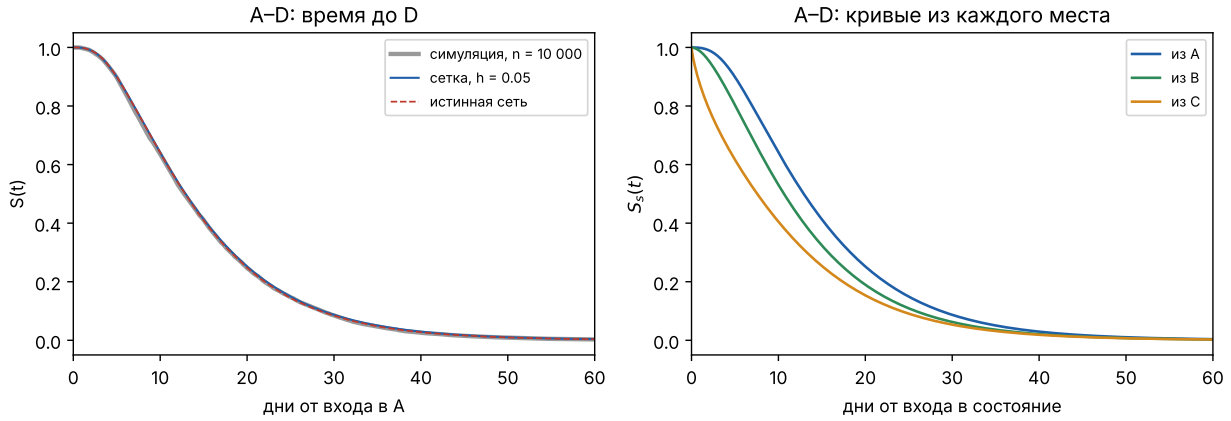


Рис. 1: A–D. Слева: сетка совпадает с симуляцией и близка к истинной сети. Справа: кривые $S_s(t)$ из каждого состояния.

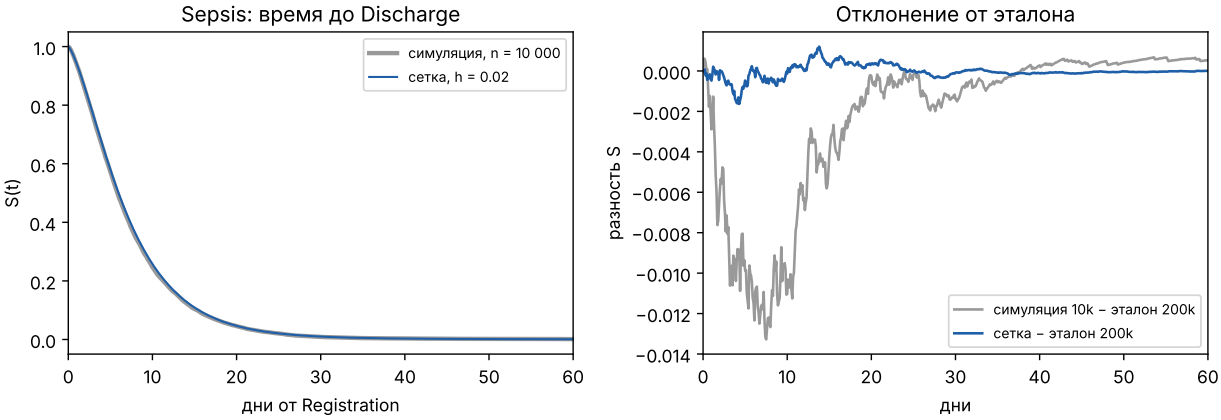


Рис. 2: Sepsis. Справа: отклонение от эталона 200 000 трасс; у сетки нет шума.

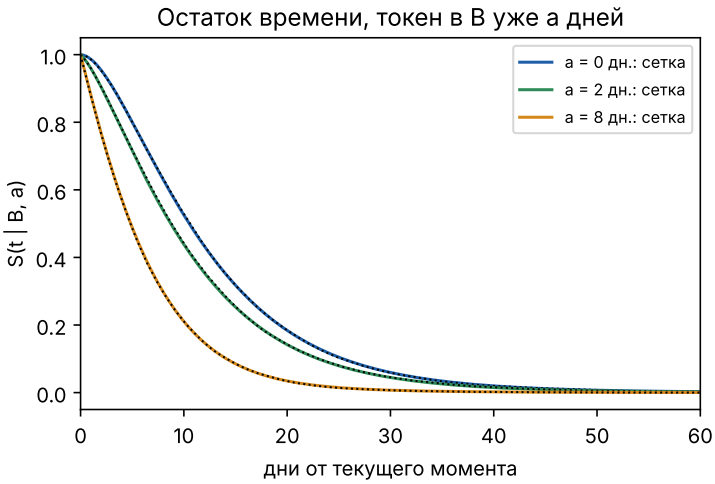


Рис. 3: Остаток времени до D, если токен уже a дней в B: сетка (цвет) и Монте-Карло (пунктир).

5 Ограничения и дальше

- Модель полумарковская: время ожидания зависит только от текущего состояния и времени с момента прихода в него, но не от истории пути. Это то же допущение, что и в оценке.
- Шаг h надо выбирать меньше характерных коротких переходов; на Sepsis — не больше 0.1 дня.
- Можно перевести метрики `km_sup`, `km_l1_days`, `ibs` на `method='grid'`: результаты станут без шума и не будут зависеть от `seed`. Пока это не сделано, чтобы не менять уже посчитанные таблицы.