

План работы (первый семестр)

Генерация журналов поведения объектов с ground truth (Process Mining + Survival Analysis)

Цель: разработать методы построения и восстановления сетей Петри по журналам событий объектов с различным известным поведением (ground truth). Совместно проверяются методы process mining (PM) и анализа выживаемости (SA). Первые исследования проводим на CRM, где объект = пользователь (сессия), события = действия с меткой времени и марками, терминальные исходы = «успех» и «отток», цензура = случайный уход или срез по окну бездействия. Нужно построить сценарий из четырёх шагов: генерация синтетических данных, discovery (восстановление с учетом survival), оценка качества восстановления при разных параметрах. Генератор будет усложняться различными профилями поведения, а discovery проверяется на реальных данных. В первую очередь важно выявлять интерпретируемые правила. Развитие работы пойдет в сторону стратифицированных сетей Петри по дереву выживаемости (стратификация относительно агрегатов по истории) или постоение деревьев выживаемости напрямую.

Статьи для обязательного изучения. PM: [1, 2, 3, 4, 5, 6, 7, 8]. SA и PM+SA: [9, 10, 11, 18]. CRM и поведение клиентов: [12, 13, 14, 15, 16, 17].

1. Рабочий pipeline

- **Этап 0.** Сделать подробное описание поведенческих наборов данных: KDD Cup 2015 (XuetangX MOOC), RetailRocket, TaoBao Behavior. Описать окружение, возможные действия пользователей, атрибуты действий. Выделить из научных статей поведенческие паттерны пользователей (сегментация пользователей) [12, 13, 14, 15, 16, 17]. Для паттернов определить поведенческие признаки (как минимум - вероятности и распределения времени переходов между действиями).
- **Этап 1.** Создать параметризованную сеть Петри для генерации журналов событий [1, 4, 5, 6]. Объекты = пользователи, состояния = действия, переходы = события. Для генерации: objectId, time, event/action (время из одного семейства распределений с разными параметрами: экспоненциальное, Вейбулл?).
- **Этап 2.** Запустить метод восстановления сети Петри (с учетом оценки вероятностей и распределения времени) на 1 паттерне поведения. КМ-оценка по журналу против истинной кривой $S(t)$ (смесь по путям), частоты переходов DFG против истинных вероятностей. Оценить качество восстановления (обычные метрики + близость функций выживания по log-rank) [8].
- **Этап 3.** Оценить качество восстановления в зависимости от поведенческих признаков при генерации. Численно проверить формулу смещения при разной доле цензуры. Медленные и редкие переходы недооцениваются. Формулу даёт руководитель.
- **Этап 4.** Создать гетерогенный журнал событий с несколькими паттернами поведения (задается список/словарь с указанием вероятности выбора типа пользователя, поведенческой схемой) [3]. Оценить качество восстановления одной сетью Петри [7].
- **Этап 5.** Добавить сегментацию клиентов по известным паттернам поведения (либо кластеризация по истории действий, либо известные признаки). 2 варианта сегментации: в листах дерева решений строятся разные сети Петри или переходы одной сети Петри параметризуются в зависимости от типа пользователя. Оценить оба решения.

2. Поведенческие профили

- **Этап 1.** Ввести $K = 3-4$ профиля поведения на одной структуре сети: профиль = вектор интенсивностей переходов + ковариаты объекта, метка профиля хранит-

ся в ground truth. Сгенерировать журнал-смесь профилей (как этап 4 в "Рабочий pipeline").

- **Этап 2.** Свести сегментацию к восстановлению профилей. Построить общие признаки по истории действий (частоты действий, межсобытийные времена, длина прошлых сессий), проверить качество кластеризации с истиной. Оценить качество в зависимости от числа восстанавливаемых профилей [9, 10].
- **Этап 3.** Оценить выживаемость по сегментам: КМ и log-rank по восстановленным сегментам против истинных кривых, СохРН с ковариатами профиля. Интерпретация правил.

3. Перенос на реальные данные (начало)

- **Этап 1.** KDD Cup 2015 (XuetangX MOOC) ¹: около 1 млн пользователей, 7 типов действий, терминальное событие = dropout, цензура = конец курса. Основной набор. Отобрать несколько курсов, словарь действий (problem, video, wiki, discussion, access, ...), кейс = пользователь в рамках курса, терминальное событие = конец курса, цензура = порог неактивности.
- **Этап 2.** Сегментация реальных пользователей поведенческими признаками и оценка интенсивностей переходов по сегментам .
- **Этап 3.** Переход на другие наборы: RetailRocket ² или TaoBao ³.
 1. RetailRocket: меньший clickstream с товарами.
 2. Taobao User Behavior (Tianchi): около 1 млн пользователей и 100 млн событий, 9 дней, 4 типа действий, категории товаров. Второй домен (второй семестр).

4. Литература

1. van der Aalst, W. M. P. (2016). Process Mining: Data Science in Action. 2nd ed. Springer. <https://www.vdaalst.com/publications/publications.html>
2. A Systematic Review on Synthetic Event Log Generation in Process Mining (EDOC 2026). <https://conf.researchr.org/details/edoc-2026/edoc-2026-papers/16/A-Systematic-Review-on-Synthetic-Event-Log-Generation-in-Process-Mining>
3. Sommers, D., Sidorova, N., van Dongen, B. (2025). A Ground Truth Approach for Assessing Process Mining Techniques. <https://arxiv.org/abs/2501.14345>, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11934509/>
4. Khan, S., Parkinson, S., Roopak, M. (2026). Reproducibility in event-log research: a parametrised generator and benchmark for event-based signatures. International Journal of Information Security. <https://link.springer.com/article/10.1007/s10207-026-01294-2>
5. Kuhn, M., Grüger, J., Bergmann, R. (2025). PALSYN: a method for synthetic multi-perspective event log generation with differential private guarantees. Process Science. <https://link.springer.com/article/10.1007/s44311-025-00033-5>
6. Kampik, T., Weske, M. (2022). Event Log Generation: An Industry Perspective. BPMDS 2022. <https://arxiv.org/abs/2202.02539>
7. Suriadi, S., et al. (2017). Event log imperfection patterns for process mining. Information Systems, 64, 132–150. <https://doi.org/10.1016/j.is.2016.07.011>
8. Leemans, S. J. J., Syring, A. F., van der Aalst, W. M. P. (2021). Earth Movers' Stochastic Conformance. Information Systems, 102, 101724. <https://doi.org/10.1016/>

¹KDD Cup 2015 (XuetangX MOOC) dataset. <https://www.kdd.org/kdd-cup/view/kdd-cup-2015>

²RetailRocket dataset. <https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset>

³TaoBao dataset. <https://tianchi.aliyun.com/dataset/649?lang=en-us>

9. Theis, J., Darabi, H. (2019). Decay Replay Mining to Predict Next Process Events. <https://arxiv.org/html/1903.05084>
10. Fahrenkrog-Petersen, S. A., et al. (2022). Fire now, fire later: alarm-based systems for prescriptive process monitoring. *Knowledge and Information Systems*, 64, 559–587. <https://arxiv.org/abs/1905.09568>
11. Benson, L., et al. (2026). Time-Related Considerations for Modeling Event-Based Data Collected via Ecological Momentary Assessment. *Advances in Methods and Practices in Psychological Science*, 9(1). <https://pmc.ncbi.nlm.nih.gov/articles/PMC13133541/>
12. Bar-El, L., et al. (2026). Analyzing the digital customer journey: a novel framework for sequential behavior modeling. *Scientific Reports*, 16, 14553. <https://pmc.ncbi.nlm.nih.gov/articles/PMC13153248/>
13. Halvorsrud, R., et al. (2024). Customer journeys and process mining. *ITM Web of Conferences*. https://www.itm-conferences.org/articles/itmconf/pdf/2024/05/itmconf_iess2024_05002.pdf
14. Dioses, J., Cordova, L. (2025). A Survey of Process Mining for Customer Management. *Engineering Proceedings*, 83(1), 7. <https://www.mdpi.com/2673-4591/83/1/7>
15. Terragni, A., Hassani, M. (2018). Analyzing customer journey with process mining: from discovery to recommendations. *FiCloud 2018*. <https://doi.org/10.1109/FiCloud.2018.00040>
16. Terragni, A., Hassani, M. (2019). Optimizing customer journey using process mining and sequence-aware recommendation. *SAC 2019*. <https://dl.acm.org/doi/10.1145/3297280.3297288>
17. Topaloglu, B., Oztaysi, B., Dogan, O. (2024). Cart-State-Aware Discovery of E-Commerce Visitor Journeys with Process Mining. *Journal of Theoretical and Applied Electronic Commerce Research*, 19(4), 138. <https://www.mdpi.com/0718-1876/19/4/138>
18. Mäkinen (2023). Estimating the effectiveness of depression care pathways: A process mining and survival analysis approach (Aalto University). <https://aaltodoc.aalto.fi/items/6512b1d4-a1c6-4d6e-98e8-70096f9a61e6/full>