

План работы

Генерация и анализ клинических траекторий (Process Mining + Survival Analysis)

Сначала строится *рабочий pipeline* на простейшей схеме генерации и одном наборе данных (построение схемы, генерация данных, восстановление схемы, оценка).

1. Рабочий pipeline

1.1 Источники данных и схема генерации

- **Этап 0** Поиск открытых наборов данных с клиническими траекториями. Обзор возможных событий/состояний пациентов, логируемых в лонгитюдных данных (например, административные, лабораторные, диагностические, скрытые).
- **Этап 1.** Построение простой сети Петри с фиксированной логикой (взять готовое исследование и повторить синтетически). Параметры сети: константные вероятности переходов, распределения времени, одно терминальное событие, одно цензурирование. Можно взять несколько типов состояний/событий и объяснить смысл переходов. Журнал содержит поля: `object_id`, `state`, `time`, `outcome`. *Результат:* простой генератор траекторий (без влияния) + JN с анализом траекторий (КМ).
- **Этап 2.** Добавляем time-invariant признаки наблюдений (возраст, пол) и учитываем в вероятностях переходов и распределениях времени. Журнал: к каждому объекту добавляется набор признаков. *Результат:* Строим КМ для каждой группы признаков (оценка различий), строим СохРН и дерево выживаемости для моделирования влияния признаков на выживаемость.
- **Этап 3.** Добавляем time-varying признаки, изменяющиеся от состояния (каждое состояние влияет на признаки наблюдений). Вероятности переходов и времени зависят от признаков. Важно придумать сценарий генерации таких данных (часть признаков отражают общую выживаемость и не изменяются, часть стабильно возрастает/убывает, часть случайно колеблется). Делаем весь процесс параметризуемым: количество признаков, состояний (и число скрытых состояний), вероятностей, распределений, влияние на признаки задается пользователем. Журнал: к каждому наблюдению добавляется набор признаков.
- **Этап 4 (альтернатива/дополнение для 3).** Возможно, для пункта 3 придется делать скрытое состояние объекта, от которого зависят вероятности переходов и признаки объекта. В журнале состояние объекта не отображается.

1.2 Модель восстановления схемы (discovery)

- **Этап 1.** Применение готовых моделей PM4Py для построения схем (+ моделирование времени между состояниями через KDE). Оцениваем качество восстановленной схемы (fitness, precision, число потерянных и лишних переходов) на отложенных сгенерированных данных.
- **Этап 2.** Добавляем оценку параметров распределений времени. Сравниваем с истинными значениями.
- **Этап 3.** Добавляем между переходами ML модели прогнозирования (классификация, регрессия, выживаемость).
- **Этап 4.** Исследуем скрытые состояния. Состояния скрываются намеренно или случайно. На уровне модели делаем кластеризацию наблюдений и добавляем/восстанавливаем признак состояния. Отдельно сравниваем скрытые и восстановленные состояния. Оцениваем качество: при каком объеме и каких признаках скрытое состояние восстановимо, а когда неотличимо.

1.3 Построение моделей выживаемости

- **Этап 1** . Построение единой time-invariant модели выживаемости на всех сгенерированных данных (не учитывает историю состояний). **Готово, придумывать не нужно.**
- **Этап 2.** Построение time-invariant модели выживаемости с учетом частичной истории состояний.
- **Этап 3.** Построение time-varying модели выживаемости. **Готово, придумывать не нужно.**
- **Этап 4.** Построение time-varying модели выживаемости с учетом скрытых состояний?
- **Этап 5 (дополнительно).** Рассмотреть несколько сценариев прогнозирования (для новых пациентов, для текущих пациентов, для пациентов с определённой историей).

1.4 Перенос на реальные данные

- **Общая логика:** берем открытый набор данных, разделяем на train/test, строим discovery на train, генерируем синтетический журнал по восстановленной схеме и обучаем модель выживаемости. Итог: сравнение правдоподобности схемы, прогнозирования test с учетом схемы и единой модели выживаемости.
- **Этап 1** . Анализ открытого набора данных с time-invariant признаками.
- **Этап 2.** Анализ открытого набора данных с time-varying признаками.
- **Этап 3 (дополнительно).** Оценка качества прогнозирования в зависимости от объёма данных.

2. Возможные наборы данных

- MIMIC-IV (нужен доступ): около 40 тыс. пациентов и 300 тыс. госпитализаций, смерть или выписка, повторные госпитализации, лонгитюдная структура.
- eICU-CRD (нужен доступ): около 200 тыс. пребываний в ОРИТ, мультицентровой набор.
- Sepsis Cases (Mannhardt, 4TU): около 1050 случаев и 15 тыс. событий, путь пациента с сепсисом, отделения, анализы, возвраты; исход — выписка или смерть.
- BPI Challenge 2011 (Dutch AMC): около 1143 случая и 150 тыс. событий, гинекологическая онкология от диагностики до наблюдения.
- Hospital Billing (Mannhardt): около 100 тыс. случаев, биллинговые события госпиталя.
- PhysioNet/CinC Challenge 2012: около 12 тыс. пациентов ОРИТ, 48 часов наблюдений, исход — смерть в стационаре.
- PhysioNet/CinC Challenge 2019: около 40 тыс. пациентов, раннее предсказание сепсиса по временным рядам.
- UCI Heart Failure Clinical Records: 299 наблюдений, смерть и цензура.