

План работы

Надёжность компонент Windows по журналам событий (Process Mining + Survival Analysis)

Сначала строится *рабочий pipeline* на одной компоненте (схема генерации, синтетический журнал, восстановление схемы, оценка надёжности). Затем генератор масштабируется на несколько компонент: сначала независимых, затем зависимых с общим исключаяющим терминальным событием и, наконец, с общими ресурсами. В конце в журнал добавляются сторонние компоненты с «отвлекающим поведением». Внутри шага указано базовое решение (Этап 1) и расширения (Этап 2, 3, ...), упорядоченные по возрастанию абстрактности и сложности.

1. Рабочий pipeline

1.1 Данные, объекты и сценарии компонент

- **Этап 0.** Изучить структуру реальных журналов Windows и особенности поведения различных компонент (SSD, HDD, RAM, Kernel ...). Описать поля журналов и их значения (`EventID`, `SourceName`, `Level`). Объект = машина (или сессия), событие = запись журнала, терминальное событие = критический сбой/отказ, цензура = конец эксплуатации или ремонт.
- **Этап 1.** Для нескольких типовых компонент описать сценарии работы: типовые `EventID`, их последовательности и фазы (запуск, работа, деградация, отказ либо нормальное завершение). Построить несколько сетей Петри для разных компонент с фиксированными вероятностями переходов и распределениями времени (места = состояния компоненты, переходы = события, на переходах заданы вероятности и распределения времени, терминальное состояние «отказ» и «цензура»). Журнал содержит поля: `EventID`, `SourceName`, `Level`, `time` (дополнить, если нужно).
- **Этап 2.** Добавить общие признаки хоста, влияющие на вероятности переходов и распределения времени (например, возраст, модель, конфигурация). Журнал: к каждому объекту (компоненте) добавляется набор признаков (отдельная таблица).
- **Этап 3.** Добавить к каждой компоненте скрытое состояние "ёмкости от которого зависят вероятности переходов и распределения времени. Одна из целей модели - моделирование процесса деградации.
- **Этап 4.** Добавить зависимость компонент через общий ресурс. Общий ресурс ограничивает срабатывания переходов, деградация ресурса повышает интенсивность отказов всех зависимых компонент (скрытая «ёмкость» ресурса).

1.2 Генерация журналов

- **Этап 1.** Отдельные журналы: по одному на компоненту (`case_id` = сессия/машина).
- **Этап 2.** Смешанный журнал: компоненты определяют взаимоисключающее состояние отказа (поломка одного = поломка всего).
- **Этап 3.** Смешанный журнал без колонки `Source` — задача атрибуции событий компонентам по `EventID` и последовательности.
- **Этап 4.** + сторонние компоненты с «отвлекающим поведением»: информационные оповещения, лицензирование, телеметрия, обновления подписок — генерируют шум, не влияющий на отказ. Изучить влияние шума на `discovery` и прогноз.

1.3 Восстановление схемы (`discovery`)

- **Этап 1.** Восстановление схемы работы каждой компоненты отдельно по чистому журналу. Оценка по `fitness`, `precision`, `generalization`, `simplicity`, подсчёт потерянных

и лишних переходов.

- **Этап 2.** Оценка параметров распределений: вероятности переходов и распределения длительностей.
- **Этап 3.** Восстановление схемы работы по смешанному журналу (с и без source). Оценка качества восстановления соотношения отдельных EventID и компонент. Оценка качества восстановления схем.

1.4 Модель надёжности (survival analysis)

- **Этап 1.** Прогнозирование времени до отказа для каждой компоненты отдельно. Сравнение прогнозов с истинными значениями.
- **Этап 2.** Конкурирующие риски: исход «какая компонента отказала первой».
- **Этап 3.** Моделирование "истощаемой емкости" общих ресурсов и каждой компоненты отдельно.

1.5 Перенос на реальные данные

- **Общая логика:** берем открытый набор данных, разделяем на train/test, строим discovery на train, генерируем синтетический журнал по восстановленной схеме и обучаем модель выживаемости. Итог: сравнение правдоподобности схемы, прогнозирования test с учетом схемы и единой модели выживаемости.
- **Этап 1 .** Анализ открытого набора данных (поведение отдельных компонент и системы в целом).
- **Этап 2.** Анализ второго открытого набора данных.
- **Этап 3 (дополнительно).** Оценка качества прогнозирования в зависимости от объёма данных.

2. Возможные наборы данных

- Dataset of Windows operating system forensics artefacts (<https://data.mendeley.com/datasets/8dfh724hvc/1>)
- LogHub Windows: журналы Windows 7, более 27 ГБ и 226+ дней.
- Реальные логи Event Viewer.