

План работы

Переходы между повторными исходами одного объекта (Process Mining + Survival Analysis)

Каждому повторному событию объекта приписан *time* (состояние). Сначала строится *рабочий pipeline* на одном наборе данных: подготовка событий, построение схемы переходов, разметка пар (время, тип следующего события), модели и оценка. Затем *pipeline* усложняется (второй домен, графовые признаки, симуляция). Внутри шага указано базовое решение (Этап 1) и расширения (Этап 2, 3, ...).

1. Рабочий pipeline

1.1 Восстановление схемы переходов (discovery)

- **Этап 0.** Изучение открытых наборов с повторными событиями одного объекта (COMPAS, Instacart) и описание типов событий. Объект = человек, состояние = тип повторного события (тип преступления или категория товара), терминальное событие = длительное отсутствие событий, цензура = конец наблюдения.
- **Этап 1.** Строим методами PM4Py граф переходов, анализируем причины переходов между состояниями. Оценка качества построенной схемы: fitness, precision, число потерянных и лишних переходов.
- **Этап 2.** Моделируем параметры переходов (вероятности и распределения времени).
- **Этап 3.** Добавляем time-invariant признаки объекта (возраст, пол, исходный балл) и признаки события (тяжесть преступления, сумма заказа). Строим между состояниями модели выживаемости (CoxPH, дерево выживаемости) и оцениваем влияние признаков на переходы.

1.2 Единая модель прогноза повторных событий (survival analysis, конкурирующие риски)

- **Этап 1 (базовый).** Каждому событию сопоставляем пару: время до следующего события T и тип следующего события K (какой из исходящих переходов сработает). Последнее событие объекта цензурировано. Признаки RFM.
- **Этап 2.** Process-aware признаки (расширение RFM): recency и time-in-place по состоянию, частоты переходов и счётчики циклов, расстояние до терминального узла, центральность посещённых состояний, conformance к типовому пути.
- **Этап 3.** Нелинейные модели типа следующего события и времени до него.
- **Этап 4 (дополнительно).** Прогноз по независимым подцепочкам и формирование дальнейшей истории (суммирование накопленного риска).

1.3 Перенос на реальные данные

- **Общая логика:** берем открытый набор данных, разделяем на train/test, строим схему переходов на train и обучаем модель. Итог: сравнение предложенных признаков и моделей с базовыми CoxRecc и RFM.
- **Этап 1.** Анализ COMPAS (повторные аресты и типы преступлений).
- **Этап 2.** Анализ Instacart (повторные заказы, переходы по матрице BCG).
- **Этап 3 (дополнительно).** Медицина (повторная госпитализация) и оценка качества прогнозирования в зависимости от объёма данных.

2. Возможные наборы данных

- COMPAS (Broward County): около 7 тыс. объектов, повторные аресты, тип и тяжесть преступления, даты, COMPAS-балл. Основной набор.
- Instacart Market Basket Analysis: около 200 тыс. покупателей и 3 млн заказов, повторные покупки и история по категориям товаров. Второй домен.

3. Литература

1. Theis, Darabi — Decay Replay Mining to Predict Next Process Events <https://arxiv.org/html/1903.05084>
2. Cry, Ballarini, Horváth, Le Gall — A framework for optimisation based stochastic process discovery (QEST 2024) <https://arxiv.org/html/2406.10817>
3. Mäkinen — Estimating the effectiveness of depression care pathways: A process mining and survival analysis approach (Aalto, 2023) <https://aaltodoc.aalto.fi/items/6512b1d4-a1c6-4d6e-98e8-70096f9a61e6/full>
4. Disease trajectories following myocardial infarction: insights from process mining of 145 million hospitalisation episodes (2023) <https://www.sciencedirect.com/science/article/pii/S2352396423003584>
5. Process Mining and Conformance Checking of Long Running Processes in Melanoma Surveillance (IJERPH 2018) <https://www.mdpi.com/1660-4601/15/12/2809>
6. Han, Greenewald, Shah — Fairness Is More Than Algorithms: Racial Disparities in Time-to-Recidivism (COMPAS, 2025) <https://www.alphaxiv.org/abs/2504.18629>
7. Recurrent Event Analysis with Ordinary Differential Equations (arXiv) <https://arxiv-vanity.com/papers/2507.20396>
8. Castet, Saleh — On the concept of survivability, with application to spacecraft and space-based networks (RESS 2012) <https://ideas.repec.org/a/eee/reensy/v99y2012icp123-138.html>
9. Volovoi — Modeling of system reliability with Petri nets with aging tokens (RESS 2004) <https://doi.org/10.1016/j.ress.2003.10.013>
10. Process mining the trajectories for adolescent-to-mother violence from longitudinal police and health service data <https://www.ovid.com/journals/janu/fulltext/10.1111/jan.15377>