从事件日志学习的 Petri 网及其生成日志的评价

控制流、决策、概率与时间的研究综述

摘要

从真实事件日志学习或构建 Petri 网，再由模型生成日志时，需要分别评价模型的形式正确性、行为覆盖及生成分布。本文围绕模型质量、生成日志质量和两网比较，梳理健全性、对齐与精确度、守卫评价、数据相关随机一致性、轨迹分布比较及条件时间评分，并说明各方法的输入、计算过程和适用范围。模型允许的行为与行为发生的概率、图结构相似与行为等价、总体时间分布与逐案例时间预测分别对应不同的评价问题。因此，评价应根据模型机制和日志信息选择互补指标，分别报告控制流、决策、概率和时间上的结果。

关键词：过程挖掘；决策挖掘；数据 Petri 网；一致性检查；随机语言；事件日志生成

目录

1 引言与研究范围 **3**

2 基本概念、符号与评价对象 **3**

2.1 活动、事件、变迁、状态与轨迹 3

2.2 允许的行为与生成概率 4

3 Petri 网模型自身的合理性与质量 **4**

3.1 结构与形式正确性 4

3.2 日志覆盖与额外允许的行为 5

3.3 复杂度与可解释性 7

3.4 执行上下文中的决策质量 7

4 模型生成的事件日志的质量 **9**

4.1 活动和轨迹的频率分布 9

4.2 完整轨迹的顺序与概率分布 10

4.3 分支选择与属性条件的关系 12

4.4 时间信息与条件时间概率评分 12

5 Petri 网之间的比较 **14**

5.1 结构差异：节点相似度和图编辑距离 14

5.2 行为差异：等价判断与近似相似度 15
5.3 概率与生成分布的差异 17

6 指标对比与评价方案 **17**
6.1 按模型能力选择互补指标 17
6.2 “真实日志到模型再到生成日志”的评价组合 18

7 研究不足与结论 **19**

1 引言与研究范围

过程模型可用于解释行为、发现偏差、预测或生成数据。重放训练日志只能检验模型对已观测行为的覆盖，生成日志的频率、时间和属性是否合理还需另行评价。生成日志在原模型中重放，则检验的是生成器与模型的一致性。因此，本文分别讨论模型自身质量、生成日志与真实日志的差异，以及两个模型之间的比较。

评价涉及三个层面。**形式正确性**指给定语义、初始状态和目标状态下的逻辑性质；**行为质量**考察模型对日志的覆盖及额外允许的行为；**经验合理性**涉及观测频率、条件决策、时间规律及领域事实。例如，健全的网仍可能给出错误的分支概率，而不健全的网也可能生成部分正常完成的案例。因此，这三个层面需要分别检验。一致性检查的基础综述提供了控制流评价框架 [1]；数据守卫、随机语言及时间概率评价进一步处理其中的决策、频率和耗时问题 [2–5]。

本文主要考察 2022–2026 年的研究，优先关注 2024–2026 年的工作。相关主题包括 process mining、decision mining、data-aware process mining、Petri net evaluation、conformance checking、stochastic process mining、event log generation、business process simulation 及 sequence similarity。文献按模型质量、生成日志质量和两网比较三个问题归纳。

2 基本概念、符号与评价对象

2.1 活动、事件、变迁、状态与轨迹

活动（activity） $a \in A$ 是业务动作的类型，例如“审核”；**事件（event）** e 是某个案例中一次被记录的发生，至少包含案例标识和活动标签，可附时间戳、生命周期状态及属性。两条“审核”记录是两个事件，可对应同一活动。只有在日志粒度和模型语义一致时，才能将一个完成事件视为一次活动执行。

接受型带标签 Petri 网记为

$$N = (P, T, F, \lambda, M_0, M_f), \qquad \lambda : T \to A \cup \{\tau\}.$$

P 是库所集合，T 是变迁集合，F 是带权弧关系，M_0, M_f 是初始和终止标识。**变迁（transition）** $t \in T$ 是模型中的可发生动作；多个变迁可以有相同活动标签，τ 表示不在日志中直接出现的静默变迁。**标识（marking）** $M : P \to \mathbb{N}$ 给出各库所 token 数，描述全网的控制流状态。数据 Petri 网（Data Petri Net, DPN）还包含变量集合 V、变量域及守卫，完整**状态（state）**为 $r = (M, \alpha)$，其中 α 是当前变量赋值。包含时间或资源机制的模型还需要相应状态信息。

运行（run） ρ 是合法的内部变迁及数据更新序列；投影 $\mathrm{obs}(\rho)$ 去掉 τ 并保留规定的可观测字段，得到**轨迹（trace）**。纯活动轨迹写成 $\sigma = \langle a_1, \ldots, a_m \rangle \in A^*$，$|\sigma| = m$ 表示事件数。含属性或时间的轨迹还记录了相应字段，比较时需先统一观测内容。**日志（event log）** L 是案例轨迹的多重集，$L(\sigma)$ 是变体 σ 出现的次数，$n = \sum_\sigma L(\sigma)$ 是案例数，$S_L = \{\sigma : L(\sigma) > 0\}$ 是变体支持集。其**经验轨迹概率**为 $p_L(\sigma) = L(\sigma)/n$，空日志的该比例不定义。

后文以 L_R 表示真实参考日志，L_G 表示生成日志，n_R, n_G 分别为两者案例数；比较的活动标签、事件粒度和案例边界应保持一致。

2.2 允许的行为与生成概率

模型语言 $\mathcal{L}(N)$ 是从 M_0 达到规定终点的全部可观测轨迹集合，记录模型允许哪些行为。普通 PN 本身并不唯一指定这些行为的发生概率：还需明确分支选择、数据更新及终止机制 [3, 6]。

在这些机制已指定且能产生完整概率分布时，以 p_N 表示由网 N 及其生成机制确定的概率分布。具体而言，$p_N(\rho)$ 是某条完整内部运行 ρ 的概率，$p_N(\sigma)$ 是最终观察到活动轨迹 σ 的概率；下标 N 指出分布来自哪个网。由于重复活动标签或静默变迁，多条内部运行可能形成同一条观测轨迹，应把它们的概率相加：

$$p_N(\sigma) = \sum_{\rho:\mathrm{obs}(\rho)=\sigma} p_N(\rho). \tag{1}$$

求和范围是投影后等于 σ 的全部完整运行。例如两条不同内部运行都被记录成 $\langle a, b\rangle$，概率分别为 0.2 和 0.3，则该观测轨迹的概率为 0.5。此式采用离散可数运行的写法，连续数据应改用相应测度及积分。

评价范围取决于模型机制及可用记录：普通 PN 可评价允许的行为；能够计算 p_N 或从生成日志估计分布时，可进一步评价发生频率；时间和数据评价则需要相应机制及观测记录。

3 Petri 网模型自身的合理性与质量

3.1 结构与形式正确性

健全性及可达性验证（soundness and reachability） 健全性检验模型能否按规定完成；日志频率和耗时的一致性则需用其他指标评价。对于 DPN，以下性质在完整状态 $r = (M, \alpha)$ 上定义 [7]。令 $r_0 = (M_0, \alpha_0)$ 是初始状态，$\to^*$ 表示零步或多步合法执行，$\xrightarrow{t}$ 表示发生变迁 t。三项条件分别是：

1. **能够完成**：无论已经合法执行到哪个状态，都至少存在一种后续执行能够到达终止标识 M_f。

$$r_0 \to^* (M, \alpha) \Longrightarrow \exists \alpha_f : (M, \alpha) \to^* (M_f, \alpha_f). \tag{2}$$

2. **正确终止**：当终止标识所需的 token 已经齐备时，不应在其他位置留下额外 token。

$$r_0 \to^* (M, \alpha),\ M \geq M_f \Longrightarrow M = M_f. \tag{3}$$

   $M \geq M_f$ 按每个库所的 token 数逐项比较。

3. **没有死变迁**：每个变迁都能在某次从初始状态出发的合法执行中发生。

$$\forall t \in T,\ \exists r, r' : r_0 \to^* r \xrightarrow{t} r'. \tag{4}$$

   结合第一项，该执行还可以继续到达终点。

验证通常给出性质成立或不成立的结论，并在不成立时提供反例；求解未完成时，结果记为未知。例如某步把 x 设为 0，后续唯一出口要求 $x > 0$，就会出现由数据条件造成的死锁。守卫各自能够成立，也不保证它们沿完整执行相互兼容。

解释与局限：上述完成条件要求存在通向终点的后续执行，仍允许无限循环。有概率机制时，还需检验目标命中概率和几乎必然终止性。安全性（每库所至多一个 token）、有界性、守恒不变量及不可达部分可作为补充检查；模型与真实过程的经验差异仍需通过日志评价。

3.2 日志覆盖与额外允许的行为

严格轨迹符合率与 token 重放 严格轨迹符合率计算多少真实案例能被模型完整解释：

$$F_{\text{strict}}(L,N)=\frac{1}{n}\sum_{\sigma}L(\sigma)\mathbf{1}[\sigma\in\mathcal{L}(N)]\in[0,1]. \tag{5}$$

$\mathbf{1}[\cdot]$ 是指示函数：条件成立取 1，否则取 0。值越大越好，1 表示全部案例均能被解释，但轻微偏差与严重偏差都会被计作不符合，也不比较模型中的发生概率。

token-based replay 以重放日志的方式，统计缺失 token 数 m、消耗数 c、遗留数 r 和产生数 p。采用全日志按案例频数加权的计数版本 [1]：

$$F_{\text{tok}}=\tfrac{1}{2}(1-m/c)+\tfrac{1}{2}(1-r/p). \tag{6}$$

在标准计数约定且 $c,p>0$ 时，值在 $[0,1]$ 中越大越好；初始/终止 token 的计数方式需与实现一致。该方法便于定位缺失及遗留 token，但在存在静默变迁和重复标签时，启发式重放可能选择错误路径。基本版不处理概率、耗时和数据守卫。

基于对齐的符合度（alignment-based fitness） 对齐把日志实际记录的事件与模型允许的执行逐步对应，以最少的修改解释日志。每一步称为一个**对齐动作**，记为 u；完整对齐记为 $\gamma=\langle u_1,\dots,u_k\rangle$。用 $\gg$ 表示“这一侧没有动作”，三种基本情况如下 [1]：

- **同步动作**：日志中的活动与模型变迁标签一致，例如日志 a 对应模型 t_a，写为 (a,t_a)。
- **日志独有动作**：日志发生了活动 a，模型在这一步没有对应变迁，写为 $(a,\gg)$。
- **模型独有动作**：模型需要执行 t，日志没有对应记录，写为 $(\gg,t)$；静默变迁也属于模型侧动作。

合法对齐须按顺序消耗完日志轨迹，且其模型侧能够从初始标识执行到终止标识。令 $\mathcal{A}(\sigma,N)$ 为轨迹 σ 与网 N 的全部合法对齐集合，$c(u)$ 为动作 u 的代价。采用同步动作 0、可见独有动作 1、静默模型动作 0 的成本，最优总成本为

$$C^*(\sigma,N)=\min_{\gamma\in\mathcal{A}(\sigma,N)}\sum_{u\in\gamma}c(u). \tag{7}$$

每个候选对齐的成本由各动作成本累加，C^* 为全部合法候选中的最小值，星号表示最优。该成本衡量日志与模型的执行偏差。

为了得到可比较的比例，令 k_N 是模型最短接受执行中的可见变迁数。先把日志的 $|\sigma|$ 个事件全部作为日志独有动作，再走完该模型执行，就得到一个成本为 $B_\sigma=|\sigma|+k_N$ 的基准对齐。全日志采用比值聚合版本：

$$F_{\text{align}}=1-\frac{\sum_\sigma L(\sigma)C^*(\sigma,N)}{\sum_\sigma L(\sigma)B_\sigma}. \tag{8}$$

$L(\sigma)$ 是该变体的案例数，因而常见轨迹贡献更大；分子是所有案例的最优成本，分母是所有案例的基准成本。在存在接受路径且分母正时，分数位于 $[0,1]$，1 表示无成本偏差；原始 C^* 非负但没有统一上界。

例如模型要求按顺序执行 a,b，日志只记录 a。一个最优对齐是

$$\gamma^*=\langle(a,t_a),(\gg,t_b)\rangle,$$

第一步同步成本 0，第二步补模型动作 b 成本 1，所以 $C^* = 1$。最短模型执行有 2 个可见变迁，$B = 1 + 2 = 3$，单案例符合度为 $1 - 1/3 = 2/3$。如果日志完整记录 ab，则两个同步动作成本均为 0，符合度为 1。该分数是按所选成本和基准归一化的偏差度量，与正确事件占比的含义不同。

纯活动对齐处理顺序，模型语义可允许循环和并发；但上述成本不评价发生概率、数值时间及数据值。数据对齐可进一步将赋值和守卫纳入同步条件，联合寻找控制流和属性修复；SMT 等技术是求解该优化问题的方法，修改成本仍需按字段及业务含义说明 [2, 8]。

精确度（precision） 允许任意活动重复的模型容易获得较高的 fitness，但对过程行为的约束很弱。precision 从额外允许行为的角度补充 fitness，检查模型在日志已经到达的执行位置允许哪些未被观测到的后续活动。下面采用日志完全符合、重放状态确定时的简化 escaping-edge 版本 [1]。

前缀上下文 h 指一条轨迹在某个位置之前已经执行的活动序列。例如在 $\langle a, b, c\rangle$ 中，第三个事件前的上下文是 $h = \langle a, b\rangle$。$w(h)$ 是日志中有多少个案例到达这个前缀；如果 3 条轨迹均以 a 开头，则 $h = \langle a\rangle$ 被访问 3 次。通过模型重放该前缀后，定义

- $E_N(h)$：模型在此处允许作为下一个事件的可见活动集合；
- $E_L(h)$：日志中在该前缀后实际出现过的下一活动集合；
- $|E_N(h)|, |E_L(h)|$：上述集合中的不同活动数，不是事件总次数。

于是

$$P_{\mathrm{EE}} = \frac{\sum_h w(h)|E_L(h)|}{\sum_h w(h)|E_N(h)|}. \tag{9}$$

分母正时范围为 $[0, 1]$，越大说明额外放行的下一活动越少。

考虑模型接受 ab, ac, ad，而日志为 $L = \{ab, ab, ac\}$。把未执行任何活动的空前缀记为 ϵ：

上下文 h	访问次数 $w(h)$	日志下一活动 $E_L(h)$	模型下一活动 $E_N(h)$
ϵ	3	$\{a\}$	$\{a\}$
$\langle a\rangle$	3	$\{b, c\}$	$\{b, c, d\}$
$\langle a, b\rangle$	2	$\varnothing$	$\varnothing$
$\langle a, c\rangle$	1	$\varnothing$	$\varnothing$

只计下一可见活动、终止位置不再产生下一活动时，分数为 $(3 \times 1 + 3 \times 2)/(3 \times 1 + 3 \times 3) = 3/4$。未观测分支 d 降低 precision。

式(9)比较允许活动与已观测活动的集合大小，并以访问次数加权，因此没有概率机制的 PN 也可计算。例中分支 b, c 的经验选择比例为 $2/3, 1/3$，而 precision 为 $3/4$。只要允许集合不变，改变模型中 b, c 的选择概率就不会改变该分数。

存在静默路径、重复标签、多重重放或不符合轨迹时，还需规定匹配及计权方式；不同 ETC 实现的具体定义可能不同。投影比较、基于负事件及反对齐的 precision 是其他思路；它们分别依赖抽象、负例推断或远离日志的模型路径 [1]。未观测行为中也可能包含合法行为，因此过高的 precision 可能伴随过拟合。概率、数据和时间仍需另行评价。

3.3 复杂度与可解释性

复杂度向量分别记录结构规模和规则复杂程度，便于比较行为质量相近的模型：

$$(|P|, |T_{\text{vis}}|, |T_\tau|, |F|, d_{\max}, n_{\text{atom}}, n_{\text{var}}, d_{\text{guard}}).$$

各项依次为库所数、可见变迁数、静默变迁数、非零弧数、最大节点度、守卫原子条件数、守卫涉及的不同变量数、守卫表达式树的最大深度。可将原子条件视为深度 1，复合逻辑根使深度增加 1；采用的计数规则应保持一致。例如“$x > 0$ 且 $x < 10$”包含 2 个原子条件、1 个变量，按此约定深度为 2。

该向量的各分量是不同口径的复杂度指标，不表示几何或状态空间维数。例如，前四项为 $(4, 3, 1, 8)$，分别表示 4 个库所、3 个可见变迁、1 个静默变迁和 8 条弧。分别报告这些指标，可保留节点总数无法体现的结构与规则差异。

这些量通常为非负计数，较小的规模往往便于阅读，但必要的过程结构和数据条件也会增加复杂度，因此没有统一理想值。本文将其作为分别报告的描述指标，并结合 fitness 和 precision 比较结构简洁性与行为质量 [1]。可解释性评价还应考察领域人员解释规则、识别反例及回答过程问题的实际表现。

3.4 执行上下文中的决策质量

守卫召回与守卫精确度（guard-recall/guard-precision） 决策挖掘研究数据条件如何约束或影响流程选择。由于活动可能重复、规则可能重叠，且部分属性组合不可达，普通分类准确率难以完整反映决策质量。Banham 等先匹配日志与控制流路径，再检查守卫 [2]。

第一步：构造候选执行。算法按观测轨迹长度界展开 play-out 树，将静默路径的条件传播到可见动作，并约简相同可见延续。树中的流 f 有源节点 $\text{src}(f)$、目标节点 $\text{tgt}(f)$、活动标签 $\text{act}(f)$ 和守卫 g_f。对某一日志活动变体 $\hat{\sigma}$，候选匹配路径 ρ 由模型流及跳过标记 $\gg$ 组成；去掉跳过后的 $\text{noskip}(\rho)$ 必须从树根连贯执行，且 $|\rho| \le |\hat{\sigma}|$。

第二步：计算每条候选的控制流匹配代价。当去掉跳过后路径非空时，原文 Def.23 采用

$$\begin{aligned}\text{cost}(\rho, \hat{\sigma}) = \big||\hat{\sigma}| - |\,\text{noskip}(\rho)|\big| + \sum_{i=1}^{|\rho|} \mathbf{1}[\text{act}(\rho_i) \neq \hat{\sigma}_i] \\ + \mathbf{1}[\text{tgt}(\text{last}(\text{noskip}(\rho))) \notin N_f].\end{aligned} \tag{10}$$

三项依次惩罚事件数差异、对应位置的活动不符，以及未在树的终点集合 N_f 结束。last 取最后一条非跳过流；跳过标记视为与业务活动不同。该匹配代价采用原文的专门定义，与前述对齐成本不同。全跳过或空轨迹没有最后一条非跳过流，需单独规定结束位置。

例如日志 $\hat{\sigma} = ab$，树允许完整路径 ab、完整路径 ac 及尚未结束的前缀 a：

候选路径	长度差	标签不符	未正确结束	总成本
完整 ab	0	0	0	0
完整 ac	0	1	0	1
前缀 a	1	0	1	2

第三步：取全部最低成本候选。令 $\mathcal{P}_{\hat{\sigma}}$ 是上述候选集合，

$$c_{\min} = \min_{\rho \in \mathcal{P}_{\hat{\sigma}}} \mathrm{cost}(\rho, \hat{\sigma}), \qquad \Gamma(\hat{\sigma}) = \{\rho \in \mathcal{P}_{\hat{\sigma}} : \mathrm{cost}(\rho, \hat{\sigma}) = c_{\min}\}.$$

Γ 包含全部最低成本路径；上例仅包含完整路径 ab，存在并列最优时则保留所有并列候选。每个候选按原文 Def.25 分配匹配权重

$$\omega(\hat{\sigma}, \rho) = \frac{\kappa^{\mathrm{cost}(\rho,\hat{\sigma})}}{|\Gamma(\hat{\sigma})|}, \qquad \kappa = 0.9. \tag{11}$$

成本为 0 时，候选路径的总权重为 1；成本非零时总权重下降。该权重用于降低较差匹配对守卫统计的贡献，与模型的分支发生概率无关。

第四步：统计守卫检查结果。沿匹配路径读取日志中已经记录的数据。$\mu_{\sigma,i-1}$ 表示到第 i 个位置前的累计赋值，未定义属性不视为满足守卫。对树中每条流 f，令

$$T_f = \sum_{\sigma \in L} \sum_{\rho \in \Gamma(\hat{\sigma})} \omega(\hat{\sigma}, \rho) \mathbf{1}[\exists i : \rho_i = f,\ g_f(\mu_{\sigma,i-1}) = \mathrm{true}], \tag{12}$$

$$E_f = \sum_{\sigma \in L} \sum_{\rho \in \Gamma(\hat{\sigma})} \frac{\mathbf{1}[\exists i : \mathrm{src}(f) = \mathrm{src}(\rho_i),\ g_f(\mu_{\sigma,i-1}) = \mathrm{true}]}{|\Gamma(\hat{\sigma})|}. \tag{13}$$

T_f 统计分支被选中且守卫成立的加权次数；E_f 统计到达相应分叉且该分支守卫成立的次数，无论该分支最终是否被选择。上述计数依赖展开树中每条流最多经过一次的性质；用于循环网时需先展开。

采用原文 Def.31 与 Def.33：

$$\mathrm{grec} = \frac{\sum_f T_f}{\sum_{\sigma \in L} |\sigma|}, \qquad \mathrm{gprec} = \frac{c_0 \mathbf{1}[\text{全部匹配成本为 } 0] + \sum_f T_f}{c_0 + \sum_f E_f}, \quad c_0 > 0. \tag{14}$$

分母有效时均在 $[0, 1]$，越大越好。**守卫召回**检查日志已经作出的选择能否通过对应条件；**守卫精确度**检查在同一批已记录数据下，模型是否还额外放行了没有被选择的分支。

只有一个二选一决策的两条长度 1 案例，实际选择均符合守卫。若两个守卫始终都真，$\sum T_f = 2, \sum E_f = 4$，取 $c_0 = 1$ 得到 $\mathrm{grec} = 1, \mathrm{gprec} = 3/5$。如果每次只有实际被选择分支的条件成立，则两项计数均为 2，两项分数均为 1。固定偏置 c_0 会影响小样本及跨日志比较，使用时应报告其值。

解释与局限：守卫精确度需结合召回率解读。例如，所有守卫均为假时，可能出现 $\mathrm{gprec} = 1$ 而 $\mathrm{grec} = 0$。此外，未访问区域受到的惩罚有限，应结合控制流 precision 评价。真实决策允许规则重叠时，还需检验条件选择概率；耗时则不在上述守卫指标的评价范围内。

数据条件下的随机选择：SLDPN 与 duEMSC　数据也可能改变分支倾向，而非确定地排除某个分支。令 $w(t, d) > 0$ 为当前数据 d 下变迁 t 的权重，$E(M, d)$ 为标识和数据条件下可用的变迁集合，则

$$p(t \mid M, d) = \frac{w(t, d)}{\sum_{u \in E(M,d)} w(u, d)}.$$

Mannhardt 等的随机带标签数据 PN（SLDPN）学习这类数据相关权重，并提出 duEMSC[3]。记 A_σ 为活动序列，D 为对应的数据序列，S_A, S_D 为日志中的两类投影支持：

$$\mathrm{duEMSC} = 1 - \sum_{D \in S_D} \sum_{A_\sigma \in S_A} \max\{p_L(A_\sigma, D) - p_N(A_\sigma \mid D) p_L(D), 0\}. \tag{15}$$

$p_L(A_\sigma, D)$ 是观测的活动–数据联合概率，$p_N(A_\sigma \mid D)$ 是给定数据序列时模型的活动序列概率。某个活动–数据组合的观测概率若高于模型提供的对应概率，差额受罚。值在 $[0,1]$ 中越大越好，理想为 1。

这里数据分布采用日志经验 $p_L(D)$，因此检查的是给定数据时的流程选择，不直接检验数据值自身的生成分布。连续数据组合过多时条件估计会稀疏，需结合支持数量解释结果。

表 1: 模型质量评价方法的条件与盲区

方法	所需信息	主要用途	基本版本的局限
健全性 [7]	网、初终态及守卫	检查完成、遗留和死变迁	不衡量真实频率与耗时
严格率/token 重放 [1]	活动日志与接受网	覆盖率及 token 偏差	重放可能启发式；无概率/数据/时间
对齐符合度 [1]	日志、网和动作成本	最少修改及顺序偏差	成本敏感；基本版无概率与耗时
控制流 precision[1]	重放上下文及后续活动	识别额外允许行为	未见不一定非法；不比较分支概率
复杂度向量	图及守卫表达式	区分结构和规则负担	可解释性仍需实际理解任务检验
守卫召回/精确度 [2]	数据日志、展开树和匹配	检查选择与条件是否一致	不直接检验概率/时间；未访问区有限
duEMSC[3]	数据相关随机权重	条件活动–数据一致性	不检验数据生成和耗时

4 模型生成的事件日志的质量

本章比较真实参考日志 L_R 与生成日志 L_G，或比较真实日志分布与模型生成概率 p_N。各指标的含义应与概率估计方法、显著性检验区分，尤其需要说明使用的是模型概率还是生成样本的经验频率。

4.1 活动和轨迹的频率分布

总变差距离（total variation distance, TV） 先确定要比较的**取值空间** $\mathcal{X}$。若关心活动频率，$x \in \mathcal{X}$ 是一个活动标签；若关心完整轨迹频率，x 就是一条活动轨迹。$p(x)$ 和 $q(x)$ 分别表示真实侧与生成侧出现取值 x 的概率：

- 活动层面，令 $C_L(a)$ 为日志 L 中活动 a 的事件数，取 $p(a) = C_{L_R}(a)/\sum_b C_{L_R}(b)$，$q(a)$ 同理；它不同于“包含该活动的案例比例”。
- 轨迹层面，取 $p(\sigma) = L_R(\sigma)/n_R$，$q(\sigma) = L_G(\sigma)/n_G$，每个案例贡献一条轨迹。若模型概率可求，也可用 $q(\sigma) = p_N(\sigma)$。

两侧使用相同空间，对未出现取值记概率 0。总变差为

$$\mathrm{TV}(p,q) = \tfrac{1}{2}\sum_{x\in\mathcal{X}} |p(x) - q(x)| = 1 - \sum_x \min\{p(x), q(x)\}. \tag{16}$$

它把每个取值的概率差相加后除以 2；取值在 $[0,1]$，0 表示两分布相同，1 表示两者支持完全不相交，越小越好。轨迹上的严格匹配形式还与 unit-EMSC 相联系：$\text{uEMSC} = 1 - \text{TV}$，它只对同一条完整轨迹保留共同概率 [3]。

例如 L_R 全为 ab，L_G 全为 ba，两侧活动 a, b 的事件比例均为 $1/2$，所以活动层 TV 为 0；完整轨迹却完全不同，轨迹层 TV 为 1。这说明活动边际相同不能保证顺序正确。若只改变时间戳而不改变活动序列，基本活动/轨迹 TV 也不会改变。

4.2 完整轨迹的顺序与概率分布

Earth movers' stochastic conformance（EMSC） EMSC 同时考虑轨迹频率和序列差异，对仅有少量活动差异的轨迹给予部分匹配 [6]。计算时，在真实侧与生成侧的轨迹之间分配概率质量，使总匹配成本最小。

在离散轨迹空间中，概率质量指分配给轨迹的概率。例如，真实日志中 100 个案例有 75 个 ab，则其经验概率为 0.75。匹配时须保留两侧各自的概率总量，轨迹差异越大，单位概率的匹配成本越高。

令 σ_i 为真实侧第 i 种轨迹，τ_j 为生成侧第 j 种轨迹，$p_i = p(\sigma_i)$、$q_j = q(\tau_j)$ 为两侧概率。先规定**轨迹距离** $d(\sigma_i, \tau_j)$：本文采用 2019 年论文的归一化 Levenshtein 编辑成本，插入、删除或替换一个活动的成本均为 1，最少编辑次数除以两条轨迹的最大长度；两空轨迹的距离定义为 0。例如 ab 变为 ac 只需替换一次，故 $d(ab, ac) = 1/2$。

π_{ij} 表示从真实轨迹 σ_i 分配给生成轨迹 τ_j 的概率份额。所有合法匹配表须满足行和等于真实概率、列和等于生成概率。EMSC 在这些表中选择总匹配成本最小的一个：

$$D_d(p,q) = \min_{\pi_{ij} \geq 0} \sum_{i,j} \pi_{ij} d(\sigma_i, \tau_j), \tag{17}$$

$$\sum_j \pi_{ij} = p_i, \qquad \sum_i \pi_{ij} = q_j, \qquad \text{EMSC}_d = 1 - D_d(p,q).$$

$\pi_{ij} d(\sigma_i, \tau_j)$ 是某一份匹配产生的加权成本；求和是整张表的成本，最小化可作为线性规划求解。所选 d 在 $[0,1]$ 时，D_d 与 EMSC 均在该区间：距离 D_d 越小越好，相似度 EMSC 越大越好，理想值分别为 0 和 1。

例如真实 $p(ab) = 3/4, p(ac) = 1/4$，生成 $q(ab) = 1/4, q(ac) = 3/4$。生成侧低估了 ab 的比例、高估了 ac 的比例，一种最优匹配如下：

真实侧 \ 生成侧	ab	ac	行和 p_i
ab	1/4	1/2	3/4
ac	0	1/4	1/4
列和 q_j	1/4	3/4	1

两类轨迹各有 $1/4$ 概率可与自身零成本匹配，剩余 $1/2$ 概率必须把 ab 与 ac 对应。因为 $d(ab, ac) = 1/2$，总成本为 $(1/2)(1/2) = 1/4$，EMSC 为 $3/4$。真实 ab 有 $1/2$ 的剩余概率、生成 ac 有 $1/2$ 的缺口，这部分不同轨迹的匹配不可避免，因此该成本已经最小。

若仅匹配完全相同的轨迹，此例的 TV 为 1/2，uEMSC 为 1/2；采用编辑成本的 EMSC 则通过较低的匹配成本体现 ab 与 ac 的局部相似性。EMSC 因而能反映顺序和频率的联合偏差，但基本版本不直接比较属性值、耗时或内部 token 因果关系。

Jensen–Shannon 距离：完整轨迹分布的严格区分 Li 等将 Jensen–Shannon 距离用于随机一致性 [4]。两侧分布均须归一化，即 $\sum_x p(x) = \sum_x q(x) = 1$。经验轨迹分布分别以本侧案例数为分母，因此即使两份日志的案例数不同，也可在同一概率空间中比较。

令 $m(x) = (p(x) + q(x))/2$ 为两分布的逐项平均，以 2 为对数底：

$$\mathrm{KL}(p\|m) = \sum_x p(x) \log_2 \frac{p(x)}{m(x)}, \tag{18}$$

$$\mathrm{JS}_{\mathrm{div}}(p, q) = \tfrac{1}{2}\,\mathrm{KL}(p\|m) + \tfrac{1}{2}\,\mathrm{KL}(q\|m), \qquad d_{\mathrm{JS}} = \sqrt{\mathrm{JS}_{\mathrm{div}}}. \tag{19}$$

约定 $0 \log 0 = 0$。散度与开平方后的距离都在 $[0, 1]$，越小越好，0 表示相同，支持完全分离时为 1；本文称“JS 距离”时指开平方后的 d_{JS}。混合分布避免了普通 KL 因对方概率为零出现无穷大。

前例的散度约为 0.18872，距离约为 0.43442。JS 将 ab 和 ac 视为不同类别，对局部序列相似性不作额外计权。因此，JS 适合严格区分完整轨迹，EMSC 则允许局部序列匹配；两者的基本活动串版本均不包含数值时间和属性。

在真实日志与模型比较中，若能查询观测轨迹的 $q(\sigma) = p_N(\sigma)$，无需枚举模型的全部轨迹。令 $S = S_{L_R}$ 为真实日志的支持，$r_{\mathrm{out}} = 1 - \sum_{\sigma \in S} q(\sigma)$ 为模型分给未观测轨迹的概率，则 [4]

$$\mathrm{JS}_{\mathrm{div}}(p, q) = \tfrac{1}{2} \left[\sum_{\sigma \in S} \left(p(\sigma) \log_2 \frac{2p(\sigma)}{p(\sigma) + q(\sigma)} + q(\sigma) \log_2 \frac{2q(\sigma)}{p(\sigma) + q(\sigma)} \right) + r_{\mathrm{out}} \right]. \tag{20}$$

残余项计入模型分配给日志支持以外轨迹的概率，计算要求 q 为完整概率分布。用有限生成日志估计 JS 时，未被样本覆盖的长尾轨迹会影响结果；原文通过不同采样规模和多次重复考察这一影响。因此，样本估计应同时报告生成规模及重复间的波动。

Entropic relevance（ER） ER 用于模型与日志的比较，衡量候选模型对固定真实日志的概率解释能力 [9]。模型分配给轨迹的概率越高，编码该轨迹所需的位数越少；若低估真实日志中的常见轨迹，平均编码长度便会增加。因此，较低的 ER 表示模型更能解释该日志的轨迹分布。

设 $p = p_{L_R}$ 为真实经验轨迹分布，$q = p_N$ 为候选生成模型的轨迹概率。$\rho_L = \sum_{\sigma : q(\sigma) > 0} p(\sigma)$ 是真实日志中模型覆盖的概率比例，二元熵为 $H_b(u) = -u \log_2 u - (1 - u) \log_2 (1 - u)$。采用原文均匀背景编码：

$$b(\sigma) = \begin{cases} -\log_2 q(\sigma), & q(\sigma) > 0, \\ (|\sigma| + 1) \log_2 (|A| + 1), & q(\sigma) = 0, \end{cases} \tag{21}$$

$$\mathrm{ER}(L_R, q) = H_b(\rho_L) + \sum_{\sigma} p(\sigma) b(\sigma). \tag{22}$$

$b(\sigma)$ 是编码一条轨迹的位数；模型允许该轨迹时用其概率编码，不允许时退回活动字母表加结束符的背景码。H_b 是区分两类编码的选择成本。结果单位为 **bits/trace**，非负、没有统一上界；对同一真实日志、同一字母表与背景规则，较小通常更好。

例如真实 100 个案例中，ab 和 ac 各 50 个。候选生成器 A 按 $0.5, 0.5$ 生成，B 按 $0.9, 0.1$ 生成。两者都覆盖所有真实轨迹，此时 $\rho_L = 1$、选择成本为 0：

$$\mathrm{ER}_A = \tfrac{1}{2}(-\log_2 0.5) + \tfrac{1}{2}(-\log_2 0.5) = 1,$$
$$\mathrm{ER}_B = \tfrac{1}{2}(-\log_2 0.9) + \tfrac{1}{2}(-\log_2 0.1) \approx 1.737.$$

B 仅给 ac 分配 10% 概率，低于真实比例，对应编码长度约 3.322 bit，从而提高了平均 ER。A 复现了两类轨迹的均衡比例，编码成本较低。这里的 1 bit/trace 来自该日志的双变体均衡分布，不能作为其他日志的统一评价阈值。

当模型覆盖所有真实轨迹时，上式可分解为

$$\mathrm{ER} = H(p) + \mathrm{KL}(p\|q), \qquad H(p) = -\sum_{\sigma} p(\sigma)\log_2 p(\sigma).$$

$H(p)$ 是固定真实日志的熵。在全覆盖条件下，ER 超过该基准的部分即为概率分配失配；真实过程存在随机性时，即使模型分布正确，ER 通常也大于 0。

只有生成日志时，可用 $q(\sigma) = L_G(\sigma)/n_G$ 估计生成分布。未采到的变体会触发背景编码，因此应将该经验估计与基于精确 p_N 的计算区分。ER 衡量轨迹编码成本，不计模型描述长度；属性和时间也仅在被纳入编码时才得到评价。

4.3 分支选择与属性条件的关系

全局轨迹分布可以发现失配，但还需知道偏差发生在哪个决策点。若日志能够对齐到同一标识及决策前数据，分支经验概率可用选择该分支的次数/该决策点访问次数估计，再以 TV 或 JS 比较同一上下文下的选择分布。并发时，多个可用变迁可能都要发生，应先区分互斥分支与独立动作，再解释这些比例。

数据评价涉及三个问题：（1）数据更新与执行选择是否满足守卫；（2）相同决策前数据下的选择概率是否接近；（3）生成的属性值及跨步骤关系是否合理。守卫召回/精确度回答第一类问题的一部分，duEMSC 主要针对第二类问题 [2, 3]；第三类问题还需直接评价属性生成分布。

对类别属性及预先定义的离散联合“上下文–属性–选择”空间，可比较相应 TV 或 JS；连续高维属性若采用分箱或其他估计，应说明表示与样本支持。属性边际接近仍可能伴随关联关系错误。例如，两组日志的风险等级比例和通过率各自相同，高风险案例的通过倾向却相反；按风险等级比较条件选择分布才能发现这类偏差。此类比较检验观测关联，因果效应则需要另外的识别条件。

4.4 时间信息与条件时间概率评分

若活动实例有开始时间 s_e 和完成时间 f_e，持续时间 $d_e = f_e - s_e$；案例到达 $a_c = \min_e s_e$，总时长 $C_c = \max_e f_e - \min_e s_e$。等待时间需知道已可执行时刻 b_e，$w_e = s_e - b_e$。并发执行中，不能把“按日志排序的上一个事件”直接当成因果前驱。只有完成时间戳时，服务与等待通常不能唯一分开 [5]。

表2列出不同时间视角及相应观测要求。确定比较对象后，可进一步在给定案例上下文下，评价模型的条件时间分布。

表 2: 时间信息的观测视角与适用前提

视角	比较内容	解释与限制
流程总时长	每个案例从开始到结束的 C_c	全程性能，不能单独定位服务/等待
绝对事件时间	日历轴上事件开始/完成时刻	需共同时间窗及明确仿真起点
相对事件时间	事件时刻减本案例到达时刻	描述案例内进度，消除绝对日历差
周期事件时间	按星期及小时等聚合事件	反映工作日历，聚合会损失细节
案例到达时间	案例首次到达时刻及分箱计数	反映输入负载，历史复现与未来预测不同
持续/等待	各活动的 d_e, w_e	需要开始、完成及使能信息

多视角来源见 [10]，到达时间评价见 [11]，持续/等待的可识别性见 [5]。

连续排序概率评分（continuous ranked probability score, CRPS） 总体时间分布相同，逐案例的时间预测仍可能有偏差。Kunkler 与 Rinderle-Ma 在 Pro3Log 研究中，将每个案例的预测总时长分布与其真实值比较 [5]。此评价适用于模型能在给定案例上下文 x_i 时产生多个时间结果的场景。

设测试案例 i 真实总时长为 y_i，模型条件累积分布函数为 $F_i(u) = P(C_i \le u \mid x_i)$，即给定上下文后“总时长不超过 u”的概率。采用其式 (6) 表达的 CDF 平方误差：

$$\mathrm{CRPS}(F_i, y_i) = \int_{-\infty}^{\infty} \big(F_i(u) - \mathbf{1}[y_i \le u]\big)^2 du, \qquad \overline{\mathrm{CRPS}} = \frac{1}{n}\sum_i \mathrm{CRPS}(F_i, y_i). \tag{23}$$

$\mathbf{1}[y_i \le u]$ 在真实完成时刻之前为 0，之后为 1；积分比较预测 CDF 与这条真实结果阶跃曲线，最后对 n 个案例取平均。可将蒙特卡洛样本的经验 CDF 代入；原文对每个测试案例采样 1000 次。

CRPS 非负、越低越好，单位为时间，没有统一上界。预测在 1 与 3 小时各有一半概率、真实为 2 小时，则 $[1,2)$ 与 $[2,3)$ 两段各积 $1/4$，得 $1/2$ 小时。单案例评分 0 要求预测全部集中于真实值；若真实过程有随机性，正确条件分布的期望评分仍可能大于 0。适当评分规则以真实条件分布为期望意义下的最优预测；校准表现仍需结合多个案例判断。

平均对数密度（log-likelihood, LL） 另一评分检查真实时间处的预测密度。若案例 i 有 K 个时间样本 z_{ik}、核带宽 $h_i > 0$，以标准正态密度 ϕ 作核，原文式 (4)–(5) 的计算可明确写为 [5]：

$$\widehat{f}_i(y) = \frac{1}{K h_i}\sum_{k=1}^{K} \phi\!\left(\frac{y - z_{ik}}{h_i}\right), \qquad \mathrm{LL} = \frac{1}{n}\sum_i \log \widehat{f}_i(y_i). \tag{24}$$

先用样本得到每个案例的核密度估计 $\widehat{f}_i$，再在真实值 y_i 处取对数并平均；此处采用自然对数。KDE 用于估计密度，LL 则根据该密度计算评分。LL 越高，模型在真实结果附近分配的密度通常越大；数值可正可负，没有 $[0,1]$ 范围。密度不同于离散轨迹概率，分数会随时间单位、带宽和变换改变，比较时须固定口径。原文按 rule-of-thumb 选带宽，并在极小密度处出现数值失败；CRPS 提供了更稳定的补充。

解释与局限：该研究按案例 80/20 划分，包含 1 个合成与 4 个真实日志；模拟重放活动序列、资源和案例到达，只重新采样时间，除 PCR 外按顺序累加，PCR 采用支持并行的过程模型 [5]。该实验设计评价的是条件时间组件，路径、资源和到达的生成质量仍需分别检验。用于预测时，条件 x_i 应限于预测时点可得的信息，避免使用事后获知的完整路径。

表 3: 生成日志评价方法的互补关系

方法	方向/单位	处理的信息	主要用途	主要限制
活动/轨迹 TV	$[0,1]$，低好	活动边际或完整串频率	直观比较概率差	硬区分类别；无数值时间
EMSC[6]	$[0,1]$，高好	完整串编辑成本与概率	容许局部序列近似	基本版无数据/时间；不等于因果识别
JS 距离 [4]	$[0,1]$，低好	完整轨迹概率	严格分布比较	不因字符串接近而给部分信用
ER[9]	bits/trace，低好	真实轨迹的模型编码成本	比较候选生成器概率解释	同一日志下比较；不含模型尺寸
守卫/duEMSC	见第3节	选择与数据条件	定位决策失配	不自动评价完整属性生成
CRPS[5]	时间，低好	逐案例条件时间 CDF	评价整条预测时间分布	需要条件生成与真实时间
时间 LL[5]	对数密度，高好	真实时间处预测密度	检验是否给真实值足够密度	单位、带宽与数值稳定性敏感

5 Petri 网之间的比较

两个网可以图结构不同而允许相同的活动序列，也可以结构完全相同而分支概率不同。比较时应先固定活动对应、初终状态及静默变迁的观察方式，再区分图结构相似、行为等价和生成分布接近。

5.1 结构差异：节点相似度和图编辑距离

节点相似度 $s(v,u)$ Dijkman 等先把过程模型表示为带类型和标签的业务过程图，再比较节点、图结构及因果关系 [12]。v,u 分别为两图中的节点，$s(v,u)\in[0,1]$ 为按给定规则计算的局部相似度。

原文讨论字符、词义、属性、类型和上下文等节点比较方式。一个可直接计算的选择是其 Def.5 的**标签字符相似度**：令 ℓ_v,ℓ_u 为标签文本，e_{char} 是把一段文本改成另一段所需的最少字符插入、删除和替换次数，则

$$s_{\text{label}}(v,u)=1-\frac{e_{\text{char}}(\ell_v,\ell_u)}{\max(|\ell_v|,|\ell_u|)}. \tag{25}$$

标签长度按字符数计；原文在比较前统一大小写并忽略部分特殊字符。两标签均为空时分母为 0，需另行规定。例如，“审核”与“复核”只需替换第一个字，相似度为 $1-1/2=0.5$。该例衡量字面接近程度，业务语义仍需结合领域知识判断。

迁移到 PN 时，应限制库所与库所、变迁与变迁对应；活动标签的业务含义、库所的初终角色及邻接关系还需核查。内部编号 p_0,q_0 不同不代表业务不同，未命名库所也不宜仅靠标签评分。下文算例先确定库所角色，再按式(25)比较活动变迁。原文的实验主要针对过程模型库检索，其结果的适用范围与学习所得 PN 的生成质量评价不同。

节点匹配相似度 令 V_1, V_2 为纳入比较的节点集合，μ 为两图节点间的**部分单射**，即一对一匹配部分节点，允许其余节点不匹配。记 $(v,u) \in \mu$ 为 v 被对应到 u。对所有满足类型及标签限制的候选映射，求

$$S_{\text{node}} = \frac{2 \max_{\mu} \sum_{(v,u)\in\mu} s(v,u)}{|V_1| + |V_2|}. \tag{26}$$

这是原文 Def.12 的节点匹配形式 [12]。分母非零时值在 $[0,1]$，越大表示元素越相似。若只比较活动节点，两图各有一个节点，标签分别为“审核”“复核”，采用上面的 0.5，则 $S_{\text{node}} = 0.5$。

计算映射时，先列出允许匹配的节点对及其分数，再选择总分最高且满足一对一约束的配对。同标签节点需结合类型或上下文分别匹配。由于该分数仅依据节点信息，相同活动集合即使执行结构不同，也可能得到相同分数。

图编辑距离（graph edit distance, GED） GED 以节点插入、删除、替换和弧插入、删除的成本度量图差异，并在所有允许的节点映射中寻找总成本最低的方案。

给定一个候选映射 μ 后，按 Dijkman 等 Def.13 计算 [12]：

1. 两侧没有被 μ 配对的节点，计入 U_V，每个节点成本 1。
2. 第一图中的弧 (v,w)，若端点分别映射到 (u,z) 且第二图有弧 (u,z)，两弧对应；否则计为需要删除/插入。第二图同理，全部未对应弧组成 U_E，每条成本 1。
3. 已匹配节点 (v,u) 的替换成本为 $2(1 - s(v,u))$。

所以候选成本与最优距离分别为

$$C(\mu) = |U_V| + |U_E| + 2 \sum_{(v,u)\in\mu} (1 - s(v,u)), \qquad D_{\text{GED}} = \min_{\mu} C(\mu). \tag{27}$$

μ 建立节点对应，弧的对应由其端点映射确定。小图可枚举候选并逐一计算，较大图通常需要优化求解；采用近似算法时应说明最优性保证。

例如两网均是一条路径：$p_0 \to t \to p_1$ 与 $q_0 \to u \to q_1$。初始、终止库所角色分别对应，故取 $\mu(p_0) = q_0, \mu(p_1) = q_1$，库所相似度均为 1；变迁标签分别为“审核”“复核”，取 $\mu(t) = u$ 及 $s(t,u) = 0.5$。此时所有节点和弧均已对应，只有标签替换成本，故 $C(\mu) = 2(1 - 0.5) = 1$。若不匹配两个变迁，就需计 2 个未匹配节点和 4 条未对应弧，成本 6。在本例的类型与初终角色约束下，最优距离为 1。

原始 GED 非负、越小越好，其上界随图规模变化。原文另有将节点、弧和替换差异分别归一化后平均的相似度版本，报告时需标明所用版本。GED 直接比较图结构，概率、数据条件和耗时不在其基本评价范围内。结构重构可能改变编辑距离而保留可见行为，因此还需结合行为比较。

5.2 行为差异：等价判断与近似相似度

轨迹语言等价与包含 固定接受状态与可见标签后，$\mathcal{L}(N_1) = \mathcal{L}(N_2)$ 表示两网允许完全相同的完整活动轨迹；$\mathcal{L}(N_1) \subseteq \mathcal{L}(N_2)$ 表示第一网的每条允许轨迹也被第二网允许。等价与包含均给出成立或不成立的判断。它保留可见活动顺序及循环语言，但不要求发生频率或数值耗时相同。

对具有有限可达状态表示的网，可构建带接受状态的转换系统，将静默变迁作为不可见步，检查两语言的差集是否为空；非空差集中的轨迹就是区分反例。对于无限状态的数据 DPN，该检验过程未必能有效完成。若只比较活动语言，也会忽略投影掉的数据条件。

双模拟（bisimulation）与分支时点 轨迹集合相同，不代表决定分支的时点相同。弱双模拟在两模型状态之间建立关系：一侧的可见动作须能由另一侧通过若干静默步、相同可见动作和若干静默步匹配，后继状态继续满足关系，反向也如此。分支双模拟进一步约束中间状态保持分支能力 [12]。采用时需明确具体版本、终止是否被观察及如何处理静默发散。

普通双模拟关注执行能力与选择结构，不要求概率和数值时间相同。两网的标识分别定义在各自的库所集合上，因此比较时需建立状态间的语义对应关系。

因果足迹相似度 因果足迹（causal footprint）用活动间的前后约束近似行为 [12]。两种基本关系是：

- look-ahead 关系 (a, B)：每次 a 发生后，在该次执行后面还会发生集合 B 中的至少一个活动。
- look-back 关系 (B, a)：每次 a 发生前，前面已经发生集合 B 中的至少一个活动。

这些关系要求约束在模型允许的执行中成立，强于日志中的先后共现。在小型无环例子中，可列出完整执行逐项验证：若允许执行只有 AB，则 $(A, \{B\})$ 的 look-ahead 和 $(\{A\}, B)$ 的 look-back 均成立；若允许执行 BA，则这两项不成立。复杂模型需采用足迹提取算法；有限模拟只能检查采样执行中的关系，无法完成全称验证。

向量化时，先确定活动对应，再以双方的活动项和 look-ahead/look-back 关系项建立共同坐标，最后根据各模型是否具备相应项填入权重。为说明原文 Def.16–18 的计算，下面采用活动一一对应且匹配相似度均为 1 的情形：活动项权重 1，涉及集合 B 的关系项权重为 $2^{-|B|}$，没有该关系则填 0。一般标签相似度不是 1 时，还按原文加入对应活动相似度权重。

取第一模型执行 AB、第二模型执行 BA。为便于展示，本例仅提取全部单元素集合的前后关系，两侧采用相同规则，未纳入多元素集合约束。共同坐标如下：

共同坐标项	模型 AB 的向量 u	模型 BA 的向量 v
活动 A	1	1
活动 B	1	1
look-ahead $(A, \{B\})$	1/2	0
look-back $(\{A\}, B)$	1/2	0
look-ahead $(B, \{A\})$	0	1/2
look-back $(\{B\}, A)$	0	1/2

于是 $u = (1, 1, 1/2, 1/2, 0, 0)$、$v = (1, 1, 0, 0, 1/2, 1/2)$，余弦相似度为

$$S_{\mathrm{cf}} = \frac{u^{\top} v}{\|u\|_2 \|v\|_2} = \frac{2}{\sqrt{2.5}\sqrt{2.5}} = 0.8. \tag{28}$$

点积 $u^{\top} v$ 只累加共同坐标上的乘积，$\|u\|_2$ 是各分量平方和的平方根。非零非负向量时分数在 $[0, 1]$，越大表示所提取活动与关系越相似；零向量须单独处理。本例中，共同活动贡献了相同分量，方向相反的前后关系则降低了相似度。

足迹是行为的近似表示：关系集合的选择会影响分数，不同行为也可能共享同一足迹。实际比较需固定提取规则和标签匹配；即使相似度为 1，也仍需单独检验语言等价。活动概率、数值耗时及完整数据约束不在该方法的比较范围内。

5.3 概率与生成分布的差异

若两网分别定义完整的 p_{N_1}, p_{N_2}，可将第4节的 EMSC、JS 或严格轨迹分布比较直接用于它们。比较对象此时是相同观测空间上的生成概率，不要求库所和变迁一一对应 [4, 6]；但活动标签和轨迹终止含义须相同，并对同一可见轨迹的多条内部运行合并概率。

表 4: 两网比较中不同层次的“相似”

层次/方法	对应前提	直接比较的信息	不能据此推出
节点/GED[12]	类型、标签、节点对应及统一图表示	元素与弧结构	行为等价或生成分布相同
语言等价/包含	接受状态、可见标签与静默语义	完整可见活动序列	发生概率或耗时相同
双模拟	状态关系及指定等价版本	后续执行与分支能力	普通版本下的概率/时间相同
因果足迹 [12]	活动对应及相同足迹提取规则	部分必然前后关系	完整语言等价
随机语言距离	完整概率及共同观测空间	活动轨迹及其发生概率	隐藏图结构相同

6 指标对比与评价方案

6.1 按模型能力选择互补指标

基础指标适用于活动日志与接受型 PN；决策、概率和时间评价则需要相应的模型机制及记录。表5汇总各方法处理的信息及关键前提。其中，顺序表示可见活动的先后关系，概率表示发生频率的比较；仅按日志频数加权的指标仍归入行为覆盖评价。顺序比较的结果也不足以识别全部内部因果关系。

表 5: 评价方法的能力矩阵：✓ 直接处理，△ 有条件或需扩展，–基本版不处理

方法	顺序	概率	时间	数据	关键前提
健全性	✓	–	△	△	明确初终态及扩展语义
活动频率 TV	–	✓	–	–	统一活动和概率归一化
对齐 fitness+precision	✓	–	△	△	合法重放、成本及匹配规则
复杂度向量	–	–	–	△	固定图及规则计数口径
轨迹 JS/EMSC/ER	✓	✓	–	△	完整轨迹概率或明确经验估计
守卫召回/精确度	✓	–	–	✓	数据、展开树及控制流匹配
duEMSC	✓	✓	–	✓	条件概率及经验数据分布
条件 CRPS/时间 LL	上下文	分布	✓	△	可生成条件时间及真实观测值

6.2 “真实日志到模型再到生成日志”的评价组合

对于由真实日志学习模型并生成日志的研究，可按以下步骤组织评价：

1. **确定观察对象**。明确案例边界、活动粒度、静默变迁及重复标签的处理、数据可得时点与终止含义，保留独立真实数据作为评价参照。
2. **检查模型质量**。检查健全性、不可达部分及死变迁，报告模型复杂度；配对使用对齐 fitness 和明确版本的 precision。两者分别反映日志偏差和额外允许的行为，发生概率则需另行检验。
3. **比较生成分布**。活动及轨迹 TV 反映比例差异，JS 严格区分完整轨迹，EMSC 允许局部序列匹配。能获得模型轨迹概率时，可用 ER 衡量其对真实日志的概率解释能力；仅有生成样本时，应标明使用经验估计。
4. **定位决策与属性问题**。有守卫时，以守卫召回/精确度检查已选分支的条件是否成立，以及其他分支是否被额外允许；有数据相关随机权重且满足前提时使用 duEMSC。属性自身及其与选择的关系还需分别比较。
5. **按可观测性评价时间**。有条件时间生成能力时，以 CRPS 评价整体预测分布，以稳定密度估计下的 LL 作补充。缺少开始或使能记录时，优先使用能够可靠识别的案例总时长，避免将组合耗时误称为纯服务时间或等待时间。
6. **比较候选模型**。按研究目标分别比较节点及弧结构、可见行为或生成分布。比较前应统一活动标签、初终状态及观测字段，并说明所用节点匹配规则、等价语义或概率估计方式。

评价结果应按模型质量、生成日志质量及模型间差异分别报告。各维度的结果可能并不一致，需结合研究目的解释，不宜在缺乏明确权重和依据时合成总分。

7 研究不足与结论

现有方法分别覆盖了过程评价的不同方面：控制流一致性检查衡量日志覆盖与额外行为，守卫指标和 duEMSC 处理执行条件及条件选择概率，EMSC、JS 和 ER 比较轨迹与概率分布，CRPS 和时间 LL 评价条件时间分布。两网比较则分别考察图结构、可见行为和生成概率，所用方法及其结论需要对应到同一比较层次 [1–6, 9, 12]。

各方法仍有明确的适用边界。守卫成立后的分支概率、活动与时间之间的联合关系，以及相同可见分布背后的内部结构，均需要额外信息才能判断。当数据更新、循环、并发和跨案例资源共同作用时，计算成本较低的单一指标尚难完整反映模型质量。

后续研究可重点考察活动、决策前属性、分支选择与耗时的联合分布，并将总体差异定位到具体分支、属性条件或时间组件。实际评价中，应同时说明日志中的可观测信息、模型的生成机制和所采用的近似计算，使指标结果能够对应到具体的建模问题。

参考文献

[1] Josep Carmona, Boudewijn van Dongen, and Matthias Weidlich. Conformance Checking: Foundations, Milestones and Challenges. In *Process Mining Handbook*, volume 448, pages 155–190. Springer, 2022. doi: 10.1007/978-3-031-08848-3_5. URL https://link.springer.com/content/pdf/10.1007/978-3-031-08848-3_5.pdf.

[2] Adam Banham, Arthur H. M. ter Hofstede, Sander J. J. Leemans, Felix Mannhardt, Robert Andrews, and Moe T. Wynn. Comparing Conformance Checking for Decision Mining: An Axiomatic Approach. *IEEE Access*, 12:60276–60298, 2024. doi: 10.1109/ACCESS.2024.3391234. URL https://pure.tue.nl/ws/portalfiles/portal/328738981/Comparing_Conformance_Checking_for_Decision_Mining_An_Axiomatic_Approach.pdf. Read version: 机构公开期刊版 24 页，含封面 1 页.

[3] Felix Mannhardt, Sander J. J. Leemans, Christopher T. Schwanen, and Massimiliano de Leoni. Modelling Data-Aware Stochastic Processes - Discovery and Conformance Checking. In *Application and Theory of Petri Nets and Concurrency*, volume 13929, pages 77–98. Springer, 2023. doi: 10.1007/978-3-031-33620-1_5. URL https://leemans.ch/publications/papers/pn2023mannhardt.pdf. Read version: 作者公开稿 23 页；正式版 22 页.

[4] Tian Li, Sander J. J. Leemans, and Artem Polyvyanyy. The Jensen-Shannon Distance for Stochastic Conformance Checking. In *Process Mining Workshops*, volume 533, pages 70–83. Springer, 2025. doi: 10.1007/978-3-031-82225-4_6. URL https://link.springer.com/content/pdf/10.1007/978-3-031-82225-4_6.pdf.

[5] Michel Kunkler and Stefanie Rinderle-Ma. Probabilistic learning of processing and waiting times: a scalable approach for process event log data. *Process Science*, 3:Article 3, 2026. doi: 10.1007/s44311-025-00036-2. URL https://link.springer.com/content/pdf/10.1007/s44311-025-00036-2.pdf.

[6] Sander J. J. Leemans, Anja F. Syring, and Wil M. P. van der Aalst. Earth Movers'Stochastic Conformance Checking. In *Business Process Management Forum*, volume 360, pages 127–143. Springer, 2019. doi: 10.1007/978-3-030-26643-1_8. URL https://link.springer.com/content/pdf/10.1007/978-3-030-26643-1_8.pdf.

[7] Paolo Felli, Marco Montali, and Sarah Winkler. Soundness of Data-Aware Processes with Arithmetic Conditions. In *Advanced Information Systems Engineering*, volume 13295, pages 389–406. Springer, 2022. doi: 10.1007/978-3-031-07472-1_23. URL https://www.inf.unibz.it/~sarwinkler/papers/FMW22b.pdf. Read version: 作者公开稿 16 页；正式会议版 18 页.

[8] Alessandro Gianola, Marco Montali, and Sarah Winkler. SMT Techniques for Data-Aware Process Mining. *KI - Künstliche Intelligenz*, 39(3):221–237, 2025. doi: 10.1007/s13218-025-00890-z. URL https://link.springer.com/content/pdf/10.1007/s13218-025-00890-z.pdf.

[9] Artem Polyvyanyy, Alistair Moffat, and Luciano Garcia-Banuelos. An Entropic Relevance Measure for Stochastic Conformance Checking in Process Mining. In *2020 2nd International Conference on Process Mining (ICPM)*, pages 97–104. IEEE, 2020. doi: 10.1109/icpm49681.2020.00024. URL https://arxiv.org/pdf/2007.09310. Read version: arXiv:2007.09310v2，2020-08-26，会议后印本 8 页.

[10] David Chapela-Campa, Ismail Benchekroun, Opher Baron, Marlon Dumas, Dmitry Krass, and Arik Senderovich. Can I Trust My Simulation Model? Measuring the Quality of Business Process Simulation Models. In *Business Process Management*, volume 14159, pages 20–37. Springer, 2023. doi: 10.1007/978-3-031-41620-0_2. URL https://arxiv.org/pdf/2303.17463. Read version: arXiv:2303.17463v1，16 页；正式会议版 18 页.

[11] Lukas Kirchdorfer, Konrad Özdemir, Han van der Aa, and Heiner Stuckenschmidt. Arrival times in dynamic environments: modeling, evaluation, and benchmarking for business process simulation. *Process Science*, 3(1):Article 9, 2026. doi: 10.1007/s44311-026-00041-z. URL https://link.springer.com/content/pdf/10.1007/s44311-026-00041-z.pdf.

[12] Remco Dijkman, Marlon Dumas, Boudewijn van Dongen, Reina Käärik, and Jan Mendling. Similarity of business process models: Metrics and evaluation. *Information Systems*, 36(2):498–516, 2011. doi: 10.1016/j.is.2010.09.006. URL https://alexandria.tue.nl/campusonly/Metis243412.pdf. Read version: 期刊排版版 19 页；2010 版权/在线，2011 卷期.