

Как прогнозировать риск отказа оборудования во времени

Докладчик:
Васильев Юлий Алексеевич

Содержание

Содержание	3
Анализ выживаемости	5
Существующие методы и их применение	9
Предложенные модификации	12
Задачи анализа надежности	16
Заключение	20



Прикладные задачи

Медицина

Объект наблюдения:
пациент

Задачи:

- Диагностика заболеваний;
- Анализ эффективности схем лечения;
- Персонализированное лечение (с учетом мониторинга состояния).

Анализ надежности

Объект наблюдения:
оборудование

Задачи:

- Оценка деградации и отказоустойчивости;
- Обеспечение бесперебойной работы системы (своевременная замена/ремонт компонент).

CRM-системы

Объект наблюдения:
клиент

Задачи:

- Анализ лояльности клиентов и рисков оттока;
- Анализ эффективности каналов коммуникации;
- Оптимизация расходов на маркетинговые кампании.

Что общего у этих задач?

Прикладные задачи

Медицина

Объект наблюдения:
пациент

Задачи:

- Диагностика заболеваний;
- Анализ эффективности схем лечения;
- Персонализированное лечение (с учетом мониторинга состояния).

Событие:

1. Летальный исход
2. Рецидив заболевания
3. Выписка

Анализ надежности

Объект наблюдения:
оборудование

Задачи:

- Оценка деградации и отказоустойчивости;
- Обеспечение бесперебойной работы системы (своевременная замена/ремонт компонент).

Событие:

Поломка/сбой
оборудования

CRM-системы

Объект наблюдения:
клиент

Задачи:



- Анализ лояльности клиентов и рисков оттока;
- Анализ эффективности каналов коммуникации;
- Оптимизация расходов на маркетинговые кампании.

Событие:

Уход клиента
(отказ от услуг)

Анализ выживаемости

- Методы анализа выживаемости (survival analysis) используются для описания контекста события и оценки вероятности наступления события во все моменты времени;
- Целевые переменные:
 - T – время от начала исследования до события или до прекращения наблюдения;
 - δ – индикатор цензурирования (выход объекта из исследования).
- Функции анализа выживаемости:
 - Выживаяния $S(t) = P(T \geq t)$ – вероятность не наступления события по истечении времени t ;
 - Плотности $f(t)$ – риск наступления события в момент t ;
 - Риска $h(t)$ – риск наступления события при условии, что событие не произошло ранее.




Почему не ...

Классификация

Прогноз факта события

Недостатки:

- Не использует время исхода;
- Неточная постановка (время события отложено);
- Точечная оценка (для эксперта не понятен «общий риск»);




Регрессия

Прогноз времени события

Недостатки:

- Удаление наблюдений с цензурой (нет истинного момента времени);
- Точечная оценка (в каком интервале возможно событие?).




Временные ряды

Мгновенная оценка риска

Недостатки:

- Невозможность сбора истинного риска для всех моментов времени (нужна прокси-переменная от эксперта);
- Невозможность долгосрочного прогноза.



Существующие методы анализа выживаемости



- 405 цитирований
- 2300+ звезд
- 100+ участников

scikit-survival

- 221 цитирований
- 1000+ звезд
- 17 участников

Существующие методы анализа выживаемости

Статистические

- **Непараметрические**
(Kaplan-Meier, Nelson-Aalen)

$$S(t) = \prod_{i:t_i \leq t} \left(1 - \frac{O_i}{N_i}\right), H(t) = \sum_{i:t_i \leq t} \frac{O_i}{N_i}$$

N_i – наблюдений на момент t_i

O_i – событий в момент t_i

- **Полупараметрические**
(Cox Proportional Hazards)

$$h(t|X) = h_0(t) \exp(\beta \cdot X)$$

- **Параметрические**
(Accelerated Failure Time)

$$S(t|X) = S_0(e^{-X \cdot \beta} t)$$

β – вектор коэффициентов

Машинного обучения

Методы на основе деревьев выживания

- Survival Tree
Разбиение пространства по статистическому критерию на области с различной выживаемостью
- Survival Random Forest
Агрегация откликов деревьев, построенных на разных подмножествах

Регрессионные $h(t|X) = h_0(t) \cdot e^{M(x)}$

- Gradient Boosting SA
Построение ансамбля деревьев решений на частичных остатках
- Component-wise GBSA
Итеративный подбор β
- DeepSurv
Отклик полносвязной NN
- CoxTime
Прогноз $M(t, x)$ с учетом времени

Построение деревьев выживания и их ансамблей

Дерево выживания

- Рекурсивное разделение пространства признаков на группы с различной выживаемостью;
- Лучшее разбиение выбирается на основе статистического критерия **log-rank**;
- Непараметрическая оценка в листах дерева.

Случайный лес выживания

- Ансамбль независимых деревьев выживаемости на бутстреп-выборках;
- В разбиении участвуют N признаков;
- Деревья строятся до исчерпания выборки;
- Количество деревьев задается извне.

Статистика log-rank определяет различия между выборками с цензурированием $H_0: h_1(t) = h_2(t)$

$$LR = \frac{\sum_{j=1}^K w_j (O_{ij} - E_{ij})}{\sqrt{\sum_{j=1}^K w_j^2 E_{ij} \left(\frac{N_j - O_j}{N_j} \right) \left(\frac{N_j - N_{i,j}}{N_j - 1} \right)}}$$

τ_i – время наступления событий;

$O_{i,j}$ – число событий в τ_j ($O_j = \sum_i O_{i,j}$);

$N_{i,j}$ – число наблюдений в τ_j ($N_j = \sum_i N_{i,j}$);


$E_{ij} = \frac{N_{ij} O_j}{N_j}$ – ожидаемое число событий в τ_j ;

$w_j = 1$ – значимость событий в τ_j .


Недостатки существующих моделей

- Работа с заполненными числовыми данными;
- Неприменимость статистических предположений: (1) случайного цензурирования, (2) пропорциональности рисков и (3) распределения времени событий на реальных данных.


Плотности распределения вероятностей времени событий не совпадают



Непараметрическая оценка Каплана-Мейера отражает реальные зависимости в данных



Модель пропорциональных рисков Кокса не учитывает пересечение прогнозов




Предложенное решение


1. Обработка категориальных и пропущенных значений на этапе поиска разбиения выборки:
 - Отображение категорий на непрерывную шкалу (WoE);
 - Поиск лучшего размещения наблюдений с пропусками.
2. Обработка **различного распределения** событий: использование взвешенных критериев log-rank для повышения чувствительности к ранним событиям.
3. Обработка случаев **информативного цензурирования**:
 1. Построение точной непараметрической оценки в листах на основе мультимодального распределения;
 2. Регуляризация дерева: учет исходного распределения событий при поиске оптимального разбиения узла.
4. Построение **интерпретируемого** дерева выживаемости;
5. Повышение **качества прогнозирования**:
 1. Bootstrap: ансамбль независимых деревьев;
 2. Boosting: адаптивный ансамбль с переВыборкой;



Пример построенного дерева выживаемости



Библиотека survivors



- Предложенные методы реализованы в виде open-source библиотеки на Python 3.10:
 - Объем кода – более 8000 строк;
 - From scratch – нет тяжелых зависимостей;
 - 18 открытых наборов данных (Med, CRM);
 - Гибкий интерфейс для создания мета-моделей (агрегация, стратификация) и проведения экспериментов;
 - 10+ модифицированных метрик качества;
 - Зарегистрировано свидетельство на ПО.
- Сценарии использования:
 - Загрузка и предобработка данных;
 - Обучение и применение моделей;
 - Оценка качества прогнозирования;
 - Визуализация результатов.

Задачи анализа надежности

Remaining Useful Life (RUL)

$$RUL = \mathbb{E}S(t) = \int_0^{t_{max}} S(t)dt$$

оценка времени до отказа
или сбоя

Примеры оборудования:


1. Компоненты ПК:
HDD, SSD, CPU, GPU;
2. Сетевые устройства:
маршрутизаторы,
коммутаторы, роутеры;
3. Промышленное
оборудование: двигатели
(NASA), турбины, буровые
установки.

Predictive Maintenance

Функция выживания

$$S(t) = P(T > t)$$


оценка деградации
оборудования



Функция риска:

$$h(t) = P(T = t)$$

оценка поломки
оборудования



Анализ деградации жестких дисков

Технология самоконтроля, анализа и отчетности (S.M.A.R.T.) — система мониторинга, включенная в компьютерные жесткие диски (HDD) и твердотельные накопители (SSD):

1. Признаки естественного старения и текущие параметры;
2. Контекст отказа оборудования известен после наступления события, а ожидаемое время отказа скрыто производителем.


ID#	ATTRIBUTE NAME	FLAG	VALUE	WORST	RAW VALUE
1	Raw_Read_Error_Rate	0x000f	078	064	69944236
3	Spin_Up_Time	0x0003	091	091	0
4	Start_Stop_Count	0x0032	100	100	13
5	Reallocated_Sector_Ct	0x0033	100	100	0
7	Seek_Error_Rate	0x000f	079	060	86099756
9	Power_On_Hours	0x0032	088	088	11011
10	Spin_Retry_Count	0x0013	100	100	0
12	Power_Cycle_Count	0x0032	100	100	13
18	Unknown_Attribute	0x000b	100	100	0
187	Reported_Uncorrect	0x0032	100	100	0
188	Command_Timeout	0x0032	100	100	0
190	Airflow_Temperature_Cel	0x0022	065	050	35 (Min/Max 29/45)
192	Power-Off_Retract_Count	0x0032	100	100	4
193	Load_Cycle_Count	0x0032	093	093	14801
194	Temperature_Celsius	0x0022	035	050	35 (0 23 0 0 0)
197	Current_Pending_Sector	0x0012	100	100	0
198	Offline_Uncorrectable	0x0010	100	100	0
199	UDMA_CRC_Error_Count	0x003e	200	200	0



Исследование стратифицирования моделей

- Статификатор работает с нечисловыми неполными данными.
- В узлах дерева статистические модели на числовых признаках.

Вывод: малая стратификация позволяет повысить качество и сохранить интерпретируемость моделей.



2018-2021

2016-2018

16

Текущие направления исследований

Конкурирующие события

Время события – время до наступления ближайшего события или до прекращения наблюдения:


$$T = \min(T_1, T_2, \dots, T_k, C),$$

Области применения:

1. Летальный исход может наступить из-за основного или сопутствующего заболевания.
2. Сбой системы связан с деградацией её компонентов.
3. Отказ клиента от кредита: досрочное погашение, невозможность оплаты, переход на другой тариф и т.д.

Time-Varying переменные

Факторы риска могут изменяться во времени (температура, нагрузка...). Необходимо учитывать историю состояний наблюдений при обучении моделей и прогнозе.



Приглашаем к совместной работе!

Требования для применения методов анализа выживаемости:

1. Постановка задачи:
 1. Возможность изменения состояния объекта во времени;
 2. Наличие четкого определения терминального события.
2. Структура данных:
 1. Наличие переменной времени до события или журнала мониторинга объектов;
 2. Наличие переменной статуса объекта (наступление события или цензурирование);
 3. Наличие признаков кумулятивного (накопительного) состояния объекта с момента наблюдения.

**Survivors
на GitHub**

